



UNIVERSIDADE FEDERAL DO CEARÁ
DEPARTAMENTO DE ENGENHARIA DE TELEINFORMÁTICA
TI0111 - ESTATÍSTICA PARA ENGENHARIA
SEMESTRE 2026.2

DAVI SOUSA TRE VIA MAGALHAES (554934)
GIOVANNI GABRIEL REMEDY MILAN (578412)
GUSTAVO OLIVEIRA SEABRA (567464)

HOMEWORK 1 - ESTATÍSTICA DESCRITIVA
BIKE SHARING DATASET

FORTALEZA – CE
SETEMBRO, 2026

Índice

INTRODUÇÃO	3
1 QUESTÃO 1: Construção do Dataset Específico do Grupo	3
1.1 Metodologia de seleção da amostra	3
1.2 Descrição do dataset original	4
1.3 Cálculos manuais: primeiras 10 observações	4
1.3.1 Cálculo da média aritmética	4
1.3.2 Cálculo da mediana	5
1.3.3 Cálculo do desvio padrão amostral	5
1.3.4 Cálculo dos quartis	5
2 QUESTÃO 2: Caracterização do Dataset	5
2.1 Classificação das variáveis	5
2.1.1 Variáveis categóricas	5
2.2 Medidas de tendência central das variáveis numéricas	6
2.3 Quartis e intervalo interquartil	6
2.3.1 Identificação de outliers	7
2.4 Análise gráfica: distribuição de <i>total_user</i>	7
2.5 Variável binária <i>low_usage</i>	8
3 QUESTÃO 3: Análise dos dias de menor utilização	8
3.1 Utilização do sistema por estação do ano	8
3.2 Utilização do sistema por condições meteorológicas	10
3.3 Relação entre temperatura e utilização diária	12
3.4 Seleção das características mais associadas à utilização	14
4 QUESTÃO 4: Aprofundando a análise do sistema de bicicletas	15
4.1 Serie temporal da temperatura.	15
4.2 Aprofundando as características escolhidas na questão 3	17
4.2.1 Temperatura	17
4.2.2 Clima	19
4.3 Analisando <i>low_usage</i> de acordo com a temperatura	20
CONCLUSÃO	21
APÊNDICES	22

A	CÓDIGO FONTE EM R UTILIZADO NAS ANÁLISES	22
A.1	Script questões 1 e 2 (main.R)	22
A.2	Script questão 3 (question3.R)	26
A.3	Script questão 4 (question4.R)	33

INTRODUÇÃO

Como Ross introduz, "in today's world that in order to learn about something you must first collect data. Statistics is the art of learning from data. It is concerned with the collection of data, its subsequent description, and its analysis, which often leads to the drawing of conclusions"(ROSS, 2020). Nesse sentido a estatística descritiva é a ferramenta primeira que permite a compreensão dos dados coletados, e por consequência dos fenômenos que eles representam, sendo definida como "the way to quantitatively describe/summarise a collection of information"(MULAS, 2026a). Para isso, tabelas e gráficos são "particularly useful ways of presenting data, often revealing important features such as the range, the degree of concentration, and the symmetry of the data"(ROSS, 2020).

A fim de "revisar e se familiarizar com os conceitos de estatística descritiva"(MULAS, 2026c), o objetivo é aplicar esses conceitos na análise de um sistema de compartilhamento de bicicletas localizado nos Estados Unidos. O conjunto de dados original, *HWI_bike_sharing.csv*, contém observações diárias referentes às condições meteorológicas, estações do ano e o volume de usuários do sistema.

1 QUESTÃO 1: CONSTRUÇÃO DO DATASET ESPECÍFICO DO GRUPO

1.1 Metodologia de seleção da amostra

Conforme as instruções da Questão 1, foi realizado o seguinte procedimento para construir o dataset específico do grupo. Os números de matrícula dos integrantes são: 554934, 546474 e 578412. O maior valor é definido como:

$$M = \max(554934, 546474, 578412) = 578412 \quad (1)$$

O valor de r é calculado como:

$$r = 1 + (M \bmod 100) = 1 + (578412 \bmod 100) = 1 + 12 = 13 \quad (2)$$

Foram selecionadas 300 observações consecutivas a partir da observação 13, conforme descrito na Tabela 1.

Tabela 1 – Informações da amostra selecionada.

Atributo	Valor
Observações selecionadas	13 a 312
Primeira data	2011-01-13
Última data	2011-11-08
Total de observações	300
Período	Aproximadamente 10 meses

1.2 Descrição do dataset original

O arquivo *HWI_bike_sharing.csv* contém dados sobre um sistema de compartilhamento de bicicletas em uma cidade norte-americana. O dataset original apresenta 731 observações diárias e as seguintes variáveis: índice de registro (*instant*), data da observação (*dteday*), estação do ano (*season*), condição meteorológica (*weathersit*), temperatura normalizada (*temp*), número de usuários casuais (*casual*) e número de usuários registrados (*registered*).

1.3 Cálculos manuais: primeiras 10 observações

As primeiras 10 observações do *data_group* correspondem aos dias 13 a 22 de janeiro de 2011. Para cada observação, a variável *total_user* foi calculada como:

$$\text{total_user} = \text{casual} + \text{registered} \quad (3)$$

Os dados das primeiras 10 observações encontram-se sintetizados na Tabela 2.

Tabela 2 – Primeiras 10 observações do dataset do grupo.

Data	Casual	Registrado	Total
2011-01-13	38	1368	1406
2011-01-14	54	1367	1421
2011-01-15	222	1026	1248
2011-01-16	251	953	1204
2011-01-17	117	883	1000
2011-01-18	9	674	683
2011-01-19	78	1572	1650
2011-01-20	83	1844	1927
2011-01-21	75	1468	1543
2011-01-22	93	888	981

1.3.1 Cálculo da média aritmética

A média aritmética é definida como:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} \quad (4)$$

Para os dados das primeiras 10 observações:

$$\bar{x} = \frac{13063}{10} = 1306,3 \text{ usuários} \quad (5)$$

1.3.2 Cálculo da mediana

A mediana é o valor central quando os dados estão ordenados. Para $n = 10$, a mediana é a média entre a 5ª e 6ª observações ordenadas.

Os valores ordenados são: 683, 981, 1000, 1204, 1248, 1406, 1421, 1543, 1650, 1927.

$$\text{Mediana} = \frac{1248 + 1406}{2} = 1327 \text{ usuários} \quad (6)$$

1.3.3 Cálculo do desvio padrão amostral

O desvio padrão amostral é calculado como:

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}} \quad (7)$$

Resultado: $s = 362,79$ usuários

1.3.4 Cálculo dos quartis

Os quartis dividem os dados em quatro partes iguais. Para Q1:

$$Q_1 = 995,25 \text{ usuários} \quad (8)$$

Para Q3:

$$Q_3 = 1569,75 \text{ usuários} \quad (9)$$

Intervalo Interquartil:

$$IQR = Q_3 - Q_1 = 1569,75 - 995,25 = 574,5 \text{ usuários} \quad (10)$$

2 QUESTÃO 2: CARACTERIZAÇÃO DO DATASET

2.1 Classificação das variáveis

O dataset de 300 observações foi caracterizado quanto à natureza de suas variáveis. As variáveis *season* e *weathersit* são categóricas, enquanto *temp*, *casual*, *registered* e a variável derivada *total_user* são numéricas contínuas.

2.1.1 Variáveis categóricas

Para a variável *season* estação do ano, foram observadas as seguintes frequências:

- 1 (Primavera): 67 observações

- 2 (Verão): 92 observações
- 3 (Outono): 94 observações
- 4 (Inverno): 47 observações

Para a variável *weathersit* (condição meteorológica):

- 1 (Céu limpo): 186 observações
- 2 (Nublado): 104 observações
- 3 (Chuva fraca): 10 observações

Não foram detectados valores ausentes no dataset.

2.2 Medidas de tendência central das variáveis numéricas

A Tabela 3 apresenta as medidas de tendência central para as variáveis numéricas.

Tabela 3 – Medidas de tendência central para variáveis numéricas.

Variável	Média	Mediana	Assimetria
temp	21,32	22,20	Negativa
casual	754,65	676,00	Positiva
registered	2814,56	3110,50	Negativa
total_user	3569,21	4038,00	Negativa

Nota: A assimetria é determinada pela relação entre média e mediana.

2.3 Quartis e intervalo interquartil

A variável analisada foi **total_user** por representar o comportamento agregado do sistema. Os quartis foram calculados utilizando a função nativa do R com método de interpolação linear.

Tabela 4 – Quartis da variável *total_user*.

Quartil	usuários
Q1	2184,50
Q2	4038,00
Q3	4681,00

O intervalo interquartil é calculado como:

$$IQR = Q_3 - Q_1 = 4681,00 - 2184,50 = 2496,50 \text{ usuários} \quad (11)$$

2.3.1 Identificação de outliers

Os limites para identificação de outliers utilizam o critério do intervalo interquartil multiplicado por 1,5:

$$\text{Limite inferior} = Q_1 - 1,5 \times IQR = 2184,50 - 1,5 \times 2496,50 = -1560,25 \quad (12)$$

$$\text{Limite superior} = Q_3 + 1,5 \times IQR = 4681,00 + 1,5 \times 2496,50 = 8425,75 \quad (13)$$

Considerando os limites calculados:

- Número de outliers detectados: 0
- Mínimo observado: 431 usuários, dentro dos limites
- Máximo observado: 6043 usuários, dentro dos limites

Conclui-se que o sistema operou de forma estável durante o período analisado, sem anomalias ou dias extremamente anormais.

2.4 Análise gráfica: distribuição de *total_user*

A distribuição da variável *total_user* apresenta as seguintes características:

- Forma: Aproximadamente simétrica com assimetria negativa moderada
- Concentração: Maioria entre 2500 e 5000 usuários
- Pico principal: Região de 4000–4500 usuários
- Cauda: Mais pronunciada no lado esquerdo

A Tabela 5 apresenta as medidas quantitativas da distribuição.

Tabela 5 – Medidas de forma da distribuição de *total_user*.

Medida	Valor	Interpretação
Assimetria (Skewness)	-0,5069	Negativa moderada
Curtose	-1,0197	Cauda mais leve que normal
Coef. Variação	38,84%	Variabilidade moderada

2.5 Variável binária *low_usage*

Uma variável binária foi criada para classificar dias de baixa utilização conforme a definição:

$$\text{low_usage} = \begin{cases} 1, & \text{se } \text{total_user} < Q_1 \\ 0, & \text{caso contrário} \end{cases} \quad (14)$$

Com critério $Q_1 = 2184,50$ usuários, os resultados encontram-se na Tabela 6.

Tabela 6 – Distribuição da variável *low_usage*.

Categoria	Contagem	Proporção	Percentual
low_usage = 0	225	0,75	75,00%
low_usage = 1	75	0,25	25,00%
Total	300	1,00	100,00%

Um dia é classificado como de baixa utilização quando o total de usuários é menor que 2184,50 usuários, correspondendo ao primeiro quartil da distribuição. Isto representa a utilização nos 25% dos dias menos ocupados.

A relevância desta categorização para futuras análises inclui:

- Investigações sobre características dos dias com baixa utilização
- Identificação de padrões sazonais e climáticos
- Informação para estratégias operacionais do sistema

3 QUESTÃO 3: ANÁLISE DOS DIAS DE MENOR UTILIZAÇÃO

Nesta questão, investigam-se as condições do clima e da estação do ano associadas aos dias de baixa utilização do sistema a partir da variável *low_usage* definida anteriormente (Seção 2).

3.1 Utilização do sistema por estação do ano

A fim de analisar o impacto da sazonalidade no uso do sistema de compartilhamento de bicicletas, a amostra de 300 dias foi agrupada pelas quatro estações do ano (*season*). Para cada subconjunto, extraíram-se o tamanho da amostra (n), a média amostral ($\bar{x}$), a mediana ($\tilde{x}$), o desvio padrão amostral (s) e a proporção de dias classificados como de baixa utilização (p_{low}).

A extração dessas métricas foi realizada computacionalmente por meio da linguagem R, isolando-se os subconjuntos lógicos e aplicando as funções descritivas nativas, conforme ilustrado no Código 1 e os resultados obtidos foram resumidos na Tabela 7.

```

71 cat("\n Season: SPRING\n")
72
73 data_spring <- subset(data_group, season == 1)
74 spring_total_users <- data_spring$total_user
75 mean_spring <- mean(spring_total_users)
76 median_spring <- median(spring_total_users)

```

Listing 1 – Trecho do script em R para o cálculo descritivo por estação (exemplo da primavera).

Tabela 7 – Indicadores estatísticos do volume de usuários categorizados por estação do ano.

Estação	n	$\bar{x}$	M_e	s	p_{low} (%)
1 (Primavera)	67	1682	1650	579	86.57
2 (Verão)	92	3775	4086	1139	14.13
3 (Outono)	94	4464	4616	798.3	3.19
4 (Inverno)	47	4067	4187	986.1	2.13

Nota: n = tamanho do subgrupo; $\bar{x}$ = média amostral; M_e = mediana; s = desvio padrão amostral; p = proporção de dias (*low_usage*).

Comparando-se os valores da Tabela 7, fica evidente algumas discrepâncias no comportamento dos usuários ao longo das estações. A primavera destaca-se como o período de menor demanda no sistema, registrando uma média de $\bar{x} = 1682$ usuários e uma mediana de $M_e = 1650$, valores inferiores à metade dos observados nas demais estações. Consequentemente, a proporção de dias de baixa utilização na primavera alcança expressivos 86,57%, evidenciando uma restrição severa ao uso do serviço neste período.

Em contrapartida, o outono e o inverno exibem os maiores patamares de movimentação, com médias de $\bar{x} = 4464$ e $\bar{x} = 4067$ usuários, respectivamente. Inclusive o outono concentra a maior mediana da amostra ($M_e = 4616$) e a menor incidência de dias de baixa utilização ($p = 3,19\%$). Já o verão, embora apresente um volume substancial de usuários ($\bar{x} = 3775$), manifesta maior dispersão interna ($s = 1139$), o que se reflete em uma faixa interquartil mais ampla.

O *boxplot* (Figura 1) corrobora os valores da Tabela 7. Nota-se que a caixa da primavera está isolada na base do gráfico, sem sobreposição com as demais distribuições, além de apresentar *outliers* superiores e inferiores. Para as estações de Verão, Outono e Inverno, as medianas posicionam-se em patamares acima de 4000 usuários. O outono apresenta uma caixa mais compacta, indicando menor dispersão, e *outliers* superiores e inferiores. Enquanto isso, o verão exibe a caixa mais ampla e os maiores *whiskers* sem nenhum *outlier*, refletindo a maior variabilidade interna, e o inverno apresenta uma caixa intermediária, com *outliers* superiores.




Figura 1 – Boxplot comparativo do total de usuários por estação do ano.

Do ponto de vista prático, tais variações demonstram que estações mais secas (como verão, outono e inverno) influenciam diretamente a atratividade do transporte de bicicletas.

3.2 Utilização do sistema por condições meteorológicas

Em complemento à análise sazonal, investigou-se a variação no volume de usuários do sistema em função das condições meteorológicas (*weathersit*). Para cada categoria climática registrada na amostra de 300 dias, computaram-se o tamanho do subgrupo (n), a média amostral ($\bar{x}$), o desvio padrão amostral (s) e a proporção de dias classificados como de baixa utilização (p_{low}).

O procedimento computacional para a extração dessas métricas e filtragem das condições de céu limpo, nublado, chuva leve e chuva forte seguiu a mesma lógica de subconjuntos lógicos em R, conforme exemplificado no Código 2.

```

215 cat("\n Weather Condition: CLEAR\n")
216
217 data_clear <- subset(data_group, weathersit == 1)
218 clear_total_users <- data_clear$total_user
219
220 mean_clear <- mean(clear_total_users)

```

Listing 2 – Trecho do script em R para o cálculo descritivo por condição meteorológica (exemplo do clima limpo).

Os resultados estatísticos obtidos para cada condição climática encontram-se resumidos na Tabela 8. Destaca-se que a categoria de chuva forte (*Heavy Rain*) não registrou ocorrências no período amostral de 300 dias analisado.

Tabela 8 – Indicadores estatísticos do volume de usuários categorizados por condição meteorológica.

Condição Meteorológica	n	$\bar{x}$	s	p_{low} (%)
1 (Céu Limpo)	186	3899	1305	18.28
2 (Nublado)	104	3173	1304	32.69
3 (Chuva Fraca)	10	1562	851.9	70.00
4 (Chuva Forte)	0	–	–	–

Nota: n = tamanho do subgrupo; $\bar{x}$ = média amostral; s = desvio padrão amostral; p_{low} = proporção de dias (*low_usage*).

A análise dos dados evidencia uma forte degradação na atratividade do serviço conforme as condições climáticas se tornam chuvosas. A maior parte dos registros concentra-se sob a condição de céu limpo ($n = 186$ dias), apresentando o maior patamar médio de utilização ($\bar{x} = 3899$ usuários) e a menor incidência de dias de baixa demanda ($p = 18,28\%$).

Sob condições nubladas, observa-se uma redução moderada na média de usuários ($\bar{x} = 3173$), acompanhada por um aumento expressivo na proporção de baixa utilização, que passa a atingir 32,69%. No entanto, o impacto mais drástico ocorre em dias de chuva fraca ($n = 10$). Embora representem uma fração minoritária da amostra, a média de usuários desaba para $\bar{x} = 1562$ (menos da metade de um dia limpo), e a proporção de dias classificados como de baixa utilização salta para 70,00%.

O *boxplot* (Figura 2) corrobora visualmente esses valores. Observa-se que a distribuição do total de usuários sob céu limpo possui sua mediana posicionada no terço superior do gráfico, com a maior amplitude de valores normais e apenas um *outlier* inferior. Conforme o clima transita para a chuva fraca, nota-se um deslocamento progressivo das caixas para patamares inferiores de utilização, acompanhado por uma compressão na dispersão dos dados nos dias chuvosos devido ao baixo volume de operações.




Figura 2 – Boxplot comparativo do total de usuários por condição meteorológica.

Dessa forma, os dados demonstram que o comportamento aparentemente inesperado observado nas estações do ano (onde períodos de outono e inverno registraram volumes elevados de demanda) encontra sua principal justificativa nas condições meteorológicas. Isso indica que a disposição dos usuários em utilizar o sistema é governada de forma muito mais direta pela presença de precipitação e cobertura de nuvens do que estritamente pela sazonalidade.

3.3 Relação entre temperatura e utilização diária

Para investigar a relação entre a temperatura ambiente (*temp*) e o volume diário de locações (*total_user*), ambas variáveis quantitativas contínuas, adotou-se o Coeficiente de Correlação Amostral de Pearson (r). O coeficiente r quantifica a força e a direção da associação linear entre duas variáveis, variando no intervalo $[-1, 1]$ (ROSS, 2020).

Para fins de validação, o cálculo foi primeiramente estruturado de forma manual para as 10 primeiras observações da amostra, computando-se os desvios em relação à média, a soma dos produtos dos desvios (covariância não normalizada) e as somas dos quadrados (variâncias não normalizadas). Posteriormente, o resultado foi confrontado com a função nativa `cor()` do R. O Código 3 exibe a implementação deste procedimento.

```

293 # limitations of the correlation coefficient in describing the observed relationship.
294 # =====
295 cat("\n3.3 Temperature vs Total Users Correlation\n")
296 cat("\n First 10th verification\n")
297
298 temp_10 <- data_g10$temp
299 users_10 <- data_g10$total_user
300 n_10 <- length(temp_10)
301
302 mean_temp_10 <- mean(temp_10)
303 mean_users_10 <- mean(users_10)
304
305 # Deviations from the mean
306 dev_temp_10 <- temp_10 - mean_temp_10
307 dev_users_10 <- users_10 - mean_users_10
308
309 sum_prod_10 <- sum(dev_temp_10 * dev_users_10)
310 sum_sq_temp_10 <- sum(dev_temp_10^2)
311 sum_sq_users_10 <- sum(dev_users_10^2)
312
313 # Manual Pearson correlation formula
314 manual_r_10 <- sum_prod_10 / sqrt(sum_sq_temp_10 * sum_sq_users_10)
315 r_10 <- cor(temp_10, users_10)
316
317 cat("   Manual r = ", manual_r_10, "\n", sep="")
318
319 cat("\n   COMPARATIONS\n")
320 cat("   Manual r: ", manual_r_10, " | R: ", r_10, " | Difference: ", abs(manual_r_10 -
  ↪   r_10), "\n", sep="")
321
322
323 cat("\n All data_group\n")
324 # Cor in R for the full dataset

```

Listing 3 – Trecho do script em R para o cálculo manual e automatizado da correlação de Pearson.

A validação no subconjunto de 10 amostras retornou um coeficiente $r \approx 0,4414$. A comparação entre o cálculo desenvolvido passo a passo e o executado pela função interna do R revelou uma diferença residual de $5,551 \times 10^{-17}$. Cumpre ressaltar que esta discrepância pequena não configura um erro metodológico, mas sim um erro de arredondamento inerente à precisão de ponto flutuante da própria linguagem (KERNS, 2010).

Ao escalar o cálculo para a amostra completa ($n = 300$), obteve-se um coeficiente de correlação $r = 0,7839$. Segundo Ross e os slides da disciplina (ROSS, 2020; MULAS, 2026b), valores de $|r|$ próximos a 0,8 indicam uma associação linear positiva de intensidade forte. Isso significa que, em termos globais, o aumento da temperatura ambiente está fortemente associado ao aumento no número de bicicletas alugadas.




Figura 3 – Diagrama de dispersão evidenciando a associação linear positiva entre a temperatura real (°C) e o total de usuários.

A análise visual do diagrama de dispersão (Figura 3) confirma a natureza positiva e proporcional da relação. Observa-se uma nuvem de pontos com clara tendência ascendente à medida que a temperatura avança dos 5°C em direção aos 25°C.

Contudo, a inspeção gráfica também evidencia as limitações da correlação linear estrita: ao atingir temperaturas extremas (próximas ou superiores a 30°C), a tendência de crescimento cessa e a nuvem de pontos aparenta estabilizar ou declinar levemente. Tal comportamento sugere a existência de um ponto de saturação de conforto térmico, a partir do qual o calor excessivo passa a desencorajar atividades físicas ao ar livre.

3.4 Seleção das características mais associadas à utilização

Com base nas análises exploratórias conduzidas nas subseções anteriores, selecionaram-se a temperatura (*temp*) e as condições meteorológicas (*weathersit*) como as duas características que exercem a maior influência sobre a demanda do sistema de compartilhamento de bicicletas.

A escolha da temperatura justifica-se quantitativamente pelo forte coeficiente de correlação linear positivo ($r = 0,7839$) e pela evidência visual do diagrama de dispersão (Figura 3), demonstrando que o conforto térmico é um impulsionador contínuo para o uso do sistema. Por sua vez, as condições meteorológicas atuam como um fator restritivo categórico diário: a ocorrência de precipitação deprime drasticamente a média de locações e eleva a probabilidade de baixa utilização para 70%, conforme a Tabela 8.

Para complementar a dinâmica dessas variáveis, elaborou-se um *boxplot* duplo comparando a distribuição da temperatura em relação à sazonalidade e ao clima (Figura 4).




Figura 4 – Painel comparativo da distribuição de temperatura pelas estações do ano e condições meteorológicas.

A inspeção do painel direito da Figura 4 revela que as temperaturas máximas apresentam um declínio visível à medida que o clima transita para cenários de chuva. Concomitantemente, o painel esquerdo expõe a forte segmentação térmica imposta pela sazonalidade, onde a primavera concentra as temperaturas mais baixas e o outono as mais altas da amostra analisada.

Sob a ótica da mobilidade urbana, esses resultados comprovam que a dinâmica do sistema é otimamente modelada pelo par *Temperatura* e *Clima*: a temperatura fornece a escala contínua de atratividade térmica, enquanto o clima atua como um limitador imediato (presença ou ausência de chuva).

4 QUESTÃO 4: APROFUNDANDO A ANÁLISE DO SISTEMA DE BICICLETAS

Nessa questão, será retomado as análises desenvolvidas anteriormente, porém aprofundando a Relação multivariável. O objetivo é fazer algumas visualizações e métricas para comprovar hipóteses anteriormente abordadas e ver a relação multivariável entre os preditores

4.1 Série temporal da temperatura.

Primeiro, para observar a relação do uso de bicicletas ao longo de aproximadamente um ano, e sua relação com as temporadas foi feito uma serie temporal.

Uma série temporal é um conjunto de dados coletados ao longo de intervalos regulares no tempo. No dataset em questão existe um preditor relacionado ao tempo que a amostra foi coletada (dtday). Esse preditor revela o fato de cada amostra ter sido coletada com o espao de um dia, começando no dia 13 de janeiro de 2011 e acabando no dia 8 de novembro de 2011, no total, 300 dias.

Com essa informação, uma serie temporal do uso de biscicletas (total_usage). a linha em preto é a série temporal, já a linha em azul retrata a tendencia do grafico;

```

42 data_tempo = data_group
43
44 data_tempo <- data_tempo |>
45   mutate(day = as.Date(dteday)) |>
46   select(-dteday) |>
47   as_tsibble(index = day)
48
49 data_tempo
50
51 #plotando a serie temporal com a função autoplot, usando o dataset que é a nossa serie
52 #temporal e a variavel que queremos plotar, no caso, o total de usuários
53 # geomline controla o tamanho da linha da serie
54 # geom_smooth faz uma linha de tendendia para melhor visualização
55 autoplot(data_tempo, total_user)+
56   geom_line(linewidth = 1.2, linetype = "solid", alpha = 0.8)+
57   geom_smooth(method="loess", se = FALSE, linewidth = 1)+
58   labs(y = "total_user",x = "dia", title = "Serie temporal de uso de bicicletas ao longo dos dias")

```

Listing 4 – Trecho do script em R para o plotagem da serie temporal.




Figura 5 – Serie temporal de total_usage

Foi então constatado que, a início do ano, o uso de bicicletas é muito baixo, porém começa a aumentar rapidamente até atingir seu apice por volta de junho, a partir do qual, começa a diminuir gradativamente até o final do ano, repetindo provavelmente esse ciclo a cada ano.

Retomando uma conclusão da questão 3, foi constatado uma correlação da temperatura com as temporadas do ano, além de uma tendencia muito forte da temperatura com o total de usuários. Além disso, segundo o dataset, as temporadas começam em 9:

Tabela 9 – tabela indicando onde começam as estações

Estação	início
1 (Primavera)	janeiro
2 (Verão)	março
3 (Outono)	junho
4 (Inverno)	setembro

Ou seja, a conclusão feita é de que, as temporadas ao longo do ano determinam a temperatura, e a temperatura influencia fortemente no total de usuários. Essa conclusão é observada a partir de que, primavera e inverno são as temporadas mais frias e, de acordo com o gráfico, possuem menos usuários, e verão e outono são mais quentes, com, de acordo com o gráfico, possuindo mais usuários.

4.2 Aprofundando as características escolhidas na questão 3

Após as análises da questão anterior, foram escolhidas 2 características que mais influenciavam na quantidade total de usuários: temperatura (**temp**) e clima (**weathersit**). A hipótese era que, a temperatura determinava a quantidade de usuários e a condição climática limitava a quantidade caso ocorresse chuva. Em especial, foi concluído que a temperatura se relacionava de uma forma não linear com a quantidade de usuários, mas que, no espaço amostral dado, esse comportamento se assemelhava a um padrão linear.

Nesse contexto, o objetivo aqui é elencar visualizações e métricas que comprovem as hipóteses para essas duas características;

4.2.1 Temperatura

Para comprovar que a temperatura está relacionada com a quantidade total de usuários, foi aprofundado a análise do gráfico de dispersão, por se traçar uma linha de tendência linear e uma linha de tendência que se adaptava à amostra no gráfico de dispersão. A figura 6 retrata as tendências de dispersão, em verde, foi traçada uma tendência linear e em vermelho foi usada uma curva de loess (suavização de gráfico de dispersão estimada localmente), que ajusta os parâmetros conforme a tendência localizada dos pontos. Ambas foram feitas usando a função "geom_smooth". Além dessa métrica, o gráfico também retrata a separação pela classe weathersit que será abordada posteriormente.

```

143 ggplot(data = data_group, mapping = aes(x=temp, y=total_user, colour = as.factor(weathersit))) +
144   geom_point(size = 2) +
145   geom_smooth(method = "lm", color = "green") +
146   geom_smooth(method = "loess", color = "red") +
147   scale_color_manual(values = c("purple", "black", "orange", "red"), labels = c("clear", "cloudy",
148   labs(title = "total_user em função da temperatura e condição de chuva")

```

Listing 5 – Trecho do script em R para plotar o grafico de dispersão.




Figura 6 – tendência do grafico de dispeção: verde: linha de tendencia linear; vermelho: linha de tendencia não linear; Area cinza: margem de erro das tendencias

Atravez desse grafico, é perceptível que a tendencia dos pontos é não linear, conforme a curva vermelha, havendo um decrescimento em cerca de 33 graus. A utilização de dois parametros pode confirmar esse fato, o coeficiente de pearson e o coeficiente de Spearman. O coeficiente de Pearson, como já citado, ressalta o quanto duas variaveis são relacionadas de forma linear, já o coeficiente de Spearman avalia a relação monotônica entre duas variáveis, de forma que, quanto mais ambas crescem juntas, mesmo que não linearmente o coeficiente será maior. A tabela 10 descreve ambos para o dataset:

Tabela 10 – tabela indicando os coeficientes de dorrelação entre temperatura e usuários

coeficiente	valor
1 (Pearson)	0.7839
2 (Searman)	0.7055

Ambos os coeficientes foram altos, indicando uma forte tendencia de crescimento. Mas como o coeficiente de Spearman tem um valor menor que o de Pearson, a Interpretação desse

valor ressalta que em alguma parte da amostra á um decrescimento, que não favorece o coeficiente de spearman. o que é confirmado visualmente pela figura 6;

4.2.2 Clima

A hipótese é que o clima está relacionado a uma maior dispersão das amostras quando em dias chuvosos, ao limitar a quantidade de usuários. Para investigar a hipótese, foram desenvolvidos dois graficos de visualização que comparavam temperatura e quantidade de usuários, para retratar a tendencia normal das amostras. Em ambos houve uma separação por classes conforma variavel (**weathersit**) para verificar se essa limitação acontecia. o primeiro grafico é a figura 6, o segundo 7.

```
199 #com um processamento anterior, ver no apendice A
200 ggplot(data = medias, mapping = aes(x=temp_cls, y=media, fill=grupo)) +
201   geom_col(position = position_dodge()) +
202   labs(title = "total_user por classe de temperatura",
203        x="temperatura por classes",
204        y="medias total_user") +
205   theme_bw()
```

Listing 6 – Trecho do script em R para o plotagem do grafico de barras.




Figura 7 – Grafico de dispersão separado pela temperatura e pela classes whartersit

O primeiro retrata na dispersão das amostras a separação por classes. É notorio que, enquanto a tendencia segue a linha de correlação entre temeratura e total de usuários, quase todas as amostras da classe de chuva fraca apresentam valores muito pequenos, provavelmente outiliers. isso é confirmado no grafico 7, no qual, a temperatura foi dividida em, fria (menor que 15 graus) normal (entre 15 e 25 graus) e quente (maior que 25 graus). Foram então pplotadas as medias para cada classe, de acordo com as medidas da tabela 11:

Tabela 11 – tabela de medias da quantidade de usuários, por temperatura, dividia em classes de clima

temperatura	media normal	media clima limpo	media colima nublado	media clima chuvoso
1 (frio)	1804	1900	1761	936
2 (normal)	3715	4096	3432	1827
3 (quente)	4524	4709	4143	1842

De acordo coos as médias, é bem perceptível que quanto maior a chuva, menor a quantidade de usuários. Em climas nublados, há pouca diferença por mais que ainda seja uma diferença significativa. Em climas chuvosos, entretando, há uma diferença muito grande, a ponto de serem considerados outliers em sua categoria.

4.3 Analisando low_usage de acordo com a temperatura

Aqui, estamos procurando quais padrões realacionados a teperatura poderia explicar o baixo uso de bicicletas.

Para essa análise, foi feito o mesmo grafico da seção 4.2, porém, diferenciando os dias em que houve pouco uso:

```

219 #novamente, utilizando a função, ggplot para plotar um grafico de disperção separado por classes
220 ggplot(data = data_group, mapping = aes(x=temp, y=total_user, colour = as.factor(low_usage))) +
221   geom_point(size = 2) +
222   geom_smooth(method = "loess", color = "red") +
223   scale_color_manual(values = c("violet", "brown"), labels = c("Normal", "Low_uSAGE"))+
224   labs(title = "total_user em função da temperatura e condição de chuva")

```

Listing 7 – Trecho do script em R para o plotagem do grafico de disperção por classes




Figura 8 – Grafico de disperção com a classe low_usage

De acordo com o gráfico e com as análises anteriores, é percebido que o baixo uso, com aproximadamente menos que 2000, ocorre principalmente em temperaturas baixas, com apenas poucos outliers, muito, em decorrência da limitação da chuva já analisada, ocorrendo em temperaturas mais altas. Esse fator confirma as nossas análises anteriores.

Uma pequena observação é que, como o baixo uso é calculado conforme a quantidade de uso, essa análise já era esperada.

CONCLUSÃO

Por fim, a partir das análises, é possível concluir que a tendência geral da utilização de bicicletas é definida por dois fatores. O primeiro sendo a temperatura, determinada de acordo com a estação. Ela fornece a linha de tendência geral, de forma não linear, mas que, no espaço amostral dado, se assemelha a uma forma linear, ou seja, a medida que ela cresce, a quantidade de usuários cresce. Além desse fator, o clima é uma variável limitante para o total de usuários, ou seja, em climas limpos, a medida de usuários segue a temperatura, mas, se aproximando de climas chuvosos, é bem provável que não se tenha muitas pessoas utilizando o serviço.

APÊNDICES

A CÓDIGO FONTE EM R UTILIZADO NAS ANÁLISES

Os códigos a seguir apresentam o código-fonte completo desenvolvido em R para a execução de todas as etapas estatísticas e gráficas deste relatório disponível no repositório (MAGALHAES; MILAN; SEABRA, 2026). Os scripts são totalmente funcionais e executáveis, tendo sido desenvolvidos segundo a Tabela 12.

Tabela 12 – Scripts em R utilizados para cada questão do relatório.

Membro	Questão	Script em R
Davi S. T. Magalhães	1 e 2	main.R
Giovanni G. R. Milan	3	question3.R
Gustavo O. Seabra	4	question4.R

A.1 Script questões 1 e 2 (main.R)

```
1 # Matrículas: 554934, 546474, 578412
2
3 library("rstudioapi")
4
5 rm(list = ls())
6 options(digits = 4)
7
8 # Carrega o dataset original
9 library("rstudioapi")
10 k <- getSourceEditorContext()$path
11 setwd(dirname(k))
12 dados_originais <- read.csv("HW1_bike_sharing.csv")
13
14 #folder_path <- "C:\\Users\\GUSTAVO\\OneDrive\\trabalhos\\faculdade\\estatistica\\Estatistica\\codigos\\Homework_1"
15 #dados_originais <- read.csv(paste0(folder_path, "HW1_bike_sharing.csv"), row.names = 1)
16
17 # Questão 1
18 cat("\n")
19 cat("\nQuestão 1: Construção do dataset\n")
20
21 # Números de matrícula do grupo
22 matriculas <- c(554934, 546474, 578412)
23
24 cat("\nInformações do Grupo\n")
25 cat("Números de matrícula: ", matriculas, "\n")
26
27 # Calcula M e r
28 M <- max(matriculas)
29 cat("Maior número de matrícula (M): ", M, "\n")
30
31 r <- 1 + (M %% 100)
32 cat("r = 1 + (M mod 100) = 1 + (", M, " mod 100) = ", r, "\n", sep = "")
33
34 # Seleciona 300 observações consecutivas
35 data_group <- dados_originais[r:(r+299), ] # [GGRM] + 300 estava selecionando no final 301, ajustei isso
```

```

36 #View(data_group)
37
38 cat("\n Amostra do Grupo \n")
39 cat("Dimensões de data_group: ", nrow(data_group), " x ", ncol(data_group), "\n", sep = "")
40 cat("Primeira data: ", as.character(data_group$dteday[1]), "\n", sep = "")
41 cat("Última data: ", as.character(data_group$dteday[nrow(data_group)]), "\n", sep = "")
42
43 cat("\nPrimeiras 10 observações de data_group:\n")
44 print(head(data_group, 10))
45
46
47 # PRIMEIRAS 10 OBSERVAÇÕES
48 cat("\n")
49 cat("As Primeiras 10 Observações\n")
50
51 dados_10 <- data_group[1:10, ]
52 dados_10$total_user <- dados_10$casual + dados_10$registered
53 total_user_10 <- dados_10$total_user
54
55 cat("\nValores de total_user (primeiras 10):\n")
56 print(total_user_10)
57
58 # MÉDIA
59 cat("\n Média \n")
60 soma <- sum(total_user_10)
61 n <- length(total_user_10)
62 media_manual <- soma / n
63 cat("Média = ", soma, " / ", n, " = ", media_manual, "\n", sep = "")
64
65 # MEDIANA
66 cat("\nMediana\n")
67 total_user_10_ordenado <- sort(total_user_10)
68 cat("Valores ordenados: ", total_user_10_ordenado, "\n", sep = " ")
69 mediana_manual <- (total_user_10_ordenado[5] + total_user_10_ordenado[6]) / 2
70 cat("Mediana = (", total_user_10_ordenado[5], " + ", total_user_10_ordenado[6], ") / 2 = ",
    ↪ mediana_manual, "\n", sep = "")
71
72 # DESVIO PADRÃO
73 cat("\nDesvio Padrão\n")
74 desvios_quadrados <- (total_user_10 - media_manual)^2
75 soma_dev_quad <- sum(desvios_quadrados)
76 variancia_manual <- soma_dev_quad / (n - 1)
77 desvio_padrao_manual <- sqrt(variancia_manual)
78 cat("Desvio Padrão = ", desvio_padrao_manual, "\n", sep = "")
79
80 # QUARTIS
81 cat("\nQuantis\n")
82 q1_pos <- (n + 1) * 0.25
83 q3_pos <- (n + 1) * 0.75
84 q1_idx_lower <- floor(q1_pos)
85 q1_idx_upper <- ceiling(q1_pos)
86 q1_frac <- q1_pos - floor(q1_pos)
87 q1_manual <- total_user_10_ordenado[q1_idx_lower] + q1_frac * (total_user_10_ordenado[q1_idx_upper] -
    ↪ total_user_10_ordenado[q1_idx_lower])
88
89 q3_idx_lower <- floor(q3_pos)
90 q3_idx_upper <- ceiling(q3_pos)
91 q3_frac <- q3_pos - floor(q3_pos)
92 q3_manual <- total_user_10_ordenado[q3_idx_lower] + q3_frac * (total_user_10_ordenado[q3_idx_upper] -
    ↪ total_user_10_ordenado[q3_idx_lower])

```

```

93
94   cat("Q1 = ", q1_manual, "\n", sep = "")
95   cat("Q2 = ", mediana_manual, "\n", sep = "")
96   cat("Q3 = ", q3_manual, "\n", sep = "")
97   cat("IQR = ", q3_manual - q1_manual, "\n", sep = "")
98
99   # VERIFICAÇÃO COM R
100  cat("\n")
101  cat("Verificação com R das primeiras 10 observações\n")
102
103  media_r <- mean(total_user_10)
104  mediana_r <- median(total_user_10)
105  desvio_r <- sd(total_user_10)
106
107  cat("\nMédia - Manual: ", media_manual, " | R: ", media_r, " | Diferença: ", abs(media_manual - media_r),
108      "\n", sep = "")
109  cat("Mediana - Manual: ", mediana_manual, " | R: ", mediana_r, "\n", sep = "")
110  cat("Desvio Padrão - Manual: ", desvio_padrao_manual, " | R: ", desvio_r, "\n", sep = "")
111
112  # QUESTÃO 2
113  cat("\n")
114  cat("Questão 2: Caracterização do Dataset\n")
115
116  # Define total_user para todo o data_group
117  data_group$total_user <- data_group$casual + data_group$registered
118
119  # 2.1
120  cat("\n2.1 Classificação das variáveis\n")
121  cat("\nCategorias de SEASON:\n")
122  print(table(data_group$season))
123  cat("\nCategorias de WEATHERSIT:\n")
124  print(table(data_group$weathersit))
125  cat("\nValores ausentes:\n")
126  print(colSums(is.na(data_group)))
127
128  # 2.2
129  cat("\n2.2 Medidas de Tendência Central\n")
130  variaveis_numericas <- c("temp", "casual", "registered", "total_user")
131
132  for (var in variaveis_numericas) {
133    cat("\n", var, ":\n", sep = "")
134    media <- mean(data_group[[var]], na.rm = TRUE)
135    mediana <- median(data_group[[var]], na.rm = TRUE)
136    cat(" Média: ", round(media, 4), "\n", sep = "")
137    cat(" Mediana: ", round(mediana, 4), "\n", sep = "")
138    if (media > mediana) {
139      cat(" Assimetria: Positiva\n")
140    } else if (media < mediana) {
141      cat(" Assimetria: Negativa\n")
142    }
143  }
144
145  # 2.3
146  cat("\n2.3 Quartis e Intervalo Interquartil\n")
147  cat("\nVariável analisada: total_user\n")
148
149  total_user <- data_group$total_user
150
151  q1 <- quantile(total_user, probs = 0.25)
152  q2 <- quantile(total_user, probs = 0.50)

```

```

152 q3 <- quantile(total_user, probs = 0.75)
153 iqr <- q3 - q1
154
155 cat("\nQ1 = ", q1, "\n", sep = "")
156 cat("Q2 = ", q2, "\n", sep = "")
157 cat("Q3 = ", q3, "\n", sep = "")
158 cat("IQR = ", iqr, "\n", sep = "")
159
160 lim_inf <- q1 - 1.5 * iqr
161 lim_sup <- q3 + 1.5 * iqr
162
163 cat("\nLimites para outliers:\n")
164 cat(" Inferior: ", lim_inf, "\n", sep = "")
165 cat(" Superior: ", lim_sup, "\n", sep = "")
166
167 outliers <- which(total_user < lim_inf | total_user > lim_sup)
168 n_outliers <- length(outliers)
169
170 cat("\nNúmero de outliers: ", n_outliers, " (", round(n_outliers / nrow(data_group) * 100, 2), "%)\n",
171     ↪ sep = "")
172
173 # 2.4 Gráficos
174 cat("\n\n2.4 Gráficos\n")
175
176 par(mfrow = c(1, 2), mar = c(4, 4, 2, 2))
177
178 # Histograma
179 hist(total_user,
180     main = "Histograma: Total de Usuários",
181     xlab = "Total de Usuários",
182     ylab = "Frequência",
183     col = "steelblue",
184     breaks = 30)
185
186 abline(v = q1, col = "red", lty = 2, lwd = 2)
187 abline(v = q2, col = "green", lty = 2, lwd = 2)
188 abline(v = q3, col = "orange", lty = 2, lwd = 2)
189 legend("topleft", c("Q1", "Q2", "Q3"), col = c("red", "green", "orange"), lty = 2)
190
191 # Boxplot
192 boxplot(total_user, main = "Boxplot: Total de Usuários", ylab = "Total de Usuários", col = "steelblue")
193
194 par(mfrow = c(1, 1))
195
196 # Medidas de forma
197 skewness_val <- mean((total_user - mean(total_user))^3) / sd(total_user)^3
198 kurtosis_val <- mean((total_user - mean(total_user))^4) / sd(total_user)^4 - 3
199
200 cat("\nMedidas de forma:\n")
201 cat(" Assimetria: ", round(skewness_val, 4), "\n", sep = "")
202 cat(" Curtose: ", round(kurtosis_val, 4), "\n", sep = "")
203
204 # 2.5
205 cat("\n\n2.5 Variavel low_usage\n")
206
207 data_group$low_usage <- ifelse(data_group$total_user < q1, 1, 0)
208
209 n_low <- sum(data_group$low_usage)
210 prop_low <- mean(data_group$low_usage)
211
212 cat("\nQ1 = ", q1, "\n", sep = "")

```

```

211 cat("Dias com baixa utilização: ", n_low, "\n", sep = "")
212 cat("Proporção: ", round(prop_low * 100, 2), "%\n", sep = "")
213
214 cat("\nTabela de frequência:\n")
215 print(table(data_group$low_usage))
216
217 # SALVAR
218 write.csv(data_group, file = "data_group.csv", row.names = FALSE)
219 save(data_group, file = "data_group.RData")
220
221 # RESUMO
222 cat("\n")
223 cat("Resumo Final\n")
224
225 cat("\nGrupo:\n")
226 cat(" Matrículas: ", paste(matriculas, collapse = ", "), "\n", sep = "")
227 cat(" M = ", M, "\n", sep = "")
228 cat(" r = ", r, "\n", sep = "")
229 cat(" Período: ", as.character(data_group$dteday[1]), " a ",
  ↳ as.character(data_group$dteday[nrow(data_group)]), "\n", sep = "")
230 cat(" Observações: ", nrow(data_group), "\n", sep = "")
231
232 cat("\nEstatísticas de total_user:\n")
233 cat(" Média: ", round(mean(total_user), 2), "\n", sep = "")
234 cat(" Mediana: ", round(median(total_user), 2), "\n", sep = "")
235 cat(" Q1: ", round(q1, 2), "\n", sep = "")
236 cat(" Q3: ", round(q3, 2), "\n", sep = "")
237 cat(" IQR: ", round(iqr, 2), "\n", sep = "")
238 cat(" Desvio Padrão: ", round(sd(total_user), 2), "\n", sep = "")
239
240 cat("\nVariavel low_usage:\n")
241 cat(" Dias com baixa utilização: ", n_low, "\n", sep = "")
242 cat(" Proporção: ", round(prop_low * 100, 2), "%\n", sep = "")

```

A.2 Script questão 3 (question3.R)

```

1 rm(list = ls()) #Cleaning environment
2 options(digits = 4)
3
4 # Set your folder path correctly (adjust if necessary before running!)
5 library("rstudioapi")
6 k <- getSourceEditorContext()$path
7 setwd(dirname(k))
8 #folder_path <- "/Users/fabiomachadomilan/Estatistica/codigos/Homework_1/"
9 load(paste0("data_group.RData"))
10 data_g10 <- data_group[1:10, ]
11
12 cat("CHECKING DATA LOADING\n")
13 cat(" > data_g10\n")
14 print(head(data_g10))
15 cat("\n > data_group\n")
16 print(tail(data_group))
17
18 cat("\n")
19 cat("Question 3: Low usage analysis\n")
20
21 # =====
22 # 1. Analyse system usage for each season of the year.

```

```

23 # For each season, calculate the mean, median, and standard deviation of total_user,
24 # and determine the proportion of days classified as low_usage. Construct a boxplot
25 # comparing the seasons and discuss the main differences observed.
26 # =====
27
28 cat("\n3.1 Per season usage\n")
29 cat("\n First 10th verification")
30 cat("\n Season: spring (only for the 10th)\n")
31
32 data_g10_spring <- subset(data_g10, season == 1)
33 spring_g10_total_users <- data_g10_spring$total_user
34
35 sum_10_spring <- sum(spring_g10_total_users)
36 n_10_spring <- length(spring_g10_total_users)
37 manual_mean_10spring <- sum_10_spring / n_10_spring
38
39 mean_10spring <- mean(spring_g10_total_users)
40 cat("    Manual mean = ", sum_10_spring, " / ", n_10_spring, " = ", mean_10spring, "\n", sep = "")
41
42 spring_g10_total_users_ordered <- sort(spring_g10_total_users)
43 cat("    Ordered values: ", spring_g10_total_users_ordered, "\n", sep = " ")
44 manual_median_10spring <- (spring_g10_total_users_ordered[5] + spring_g10_total_users_ordered[6]) / 2
45 cat("    Median = (", spring_g10_total_users_ordered[5], " + ", spring_g10_total_users_ordered[6], ") / 2 =
    ↪ ", manual_median_10spring, "\n", sep = "")
46
47 median_10spring <- median(spring_g10_total_users)
48
49
50 squared_deviations_10spring <- (spring_g10_total_users - manual_mean_10spring)^2
51 sum_sqr_dev_10spring <- sum(squared_deviations_10spring)
52 manual_variance_10spring <- sum_sqr_dev_10spring / (n_10_spring - 1)
53 manual_std_10spring <- sqrt(manual_variance_10spring)
54 cat("    Standard Deviation = ", manual_std_10spring, "\n", sep = "")
55
56 std_10spring <- sd(spring_g10_total_users)
57
58
59 manual_prop_low_10spring <- sum(data_g10_spring$low_usage) / nrow(data_g10_spring)
60 cat("    Proportion of low_usage days = ", manual_prop_low_10spring, "\n", sep = "")
61
62 prop_low_10spring <- mean(data_g10_spring$low_usage)
63
64 cat("\n    COMPARISONS")
65 cat("\n    Manual mean: ", manual_mean_10spring, " | R: ", mean_10spring, " | Difference: ",
    ↪ abs(manual_mean_10spring - mean_10spring), "\n", sep = "")
66 cat("    Manual median: ", manual_median_10spring, " | R: ", median_10spring, " | Difference: ",
    ↪ abs(manual_median_10spring - median_10spring), "\n", sep = "")
67 cat("    Manual std: ", manual_std_10spring, " | R: ", std_10spring, " | Difference: ",
    ↪ abs(manual_std_10spring - std_10spring), "\n", sep = "")
68 cat("    Manual low_usage days: ", manual_prop_low_10spring, " | R: ", prop_low_10spring, " | Difference:
    ↪ ", abs(manual_prop_low_10spring - prop_low_10spring), "\n", sep = "")
69
70 cat("\n All data_group")
71 cat("\n Season: SPRING\n")
72
73 data_spring <- subset(data_group, season == 1)
74 spring_total_users <- data_spring$total_user
75 mean_spring <- mean(spring_total_users)
76 median_spring <- median(spring_total_users)
77 std_spring <- sd(spring_total_users)

```

```

78 prop_low_spring <- mean(data_spring$low_usage)
79
80 cat("      n: ", length(spring_total_users), "\n", sep = "")
81 cat("      mean: ", mean_spring, "\n", sep = "")
82 cat("      median: ", median_spring, "\n", sep = "")
83 cat("      std: ", std_spring, "\n", sep = "")
84 cat("      low_usage days: ", prop_low_spring, "\n", sep = "")
85
86 cat("\n Season: SUMMER\n")
87
88 data_summer <- subset(data_group, season == 2)
89 summer_total_users <- data_summer$total_user
90 mean_summer <- mean(summer_total_users)
91 median_summer <- median(summer_total_users)
92 std_summer <- sd(summer_total_users)
93 prop_low_summer <- mean(data_summer$low_usage)
94
95 cat("      n: ", length(summer_total_users), "\n", sep = "")
96 cat("      mean: ", mean_summer, "\n", sep = "")
97 cat("      median: ", median_summer, "\n", sep = "")
98 cat("      std: ", std_summer, "\n", sep = "")
99 cat("      low_usage days: ", prop_low_summer, "\n", sep = "")
100
101 cat("\n Season: AUTUMN\n")
102
103 data_autumn <- subset(data_group, season == 3)
104 autumn_total_users <- data_autumn$total_user
105 mean_autumn <- mean(autumn_total_users)
106 median_autumn <- median(autumn_total_users)
107 std_autumn <- sd(autumn_total_users)
108 prop_low_autumn <- mean(data_autumn$low_usage)
109
110 cat("      n: ", length(autumn_total_users), "\n", sep = "")
111 cat("      mean: ", mean_autumn, "\n", sep = "")
112 cat("      median: ", median_autumn, "\n", sep = "")
113 cat("      std: ", std_autumn, "\n", sep = "")
114 cat("      low_usage days: ", prop_low_autumn, "\n", sep = "")
115
116 cat("\n Season: WINTER\n")
117
118 data_winter <- subset(data_group, season == 4)
119 winter_total_users <- data_winter$total_user
120 mean_winter <- mean(winter_total_users)
121 median_winter <- median(winter_total_users)
122 std_winter <- sd(winter_total_users)
123 prop_low_winter <- mean(data_winter$low_usage)
124
125 cat("      n: ", length(winter_total_users), "\n", sep = "")
126 cat("      mean: ", mean_winter, "\n", sep = "")
127 cat("      median: ", median_winter, "\n", sep = "")
128 cat("      std: ", std_winter, "\n", sep = "")
129 cat("      low_usage days: ", prop_low_winter, "\n", sep = "")
130
131 pdf(file = "/Users/fabiomachadomilan/Estatistica/Docs/assets/boxplot_season.pdf", width = 8, height = 6)
132
133 data_group$season_name <- factor(data_group$season,
134                                 levels = c(1, 2, 3, 4),
135                                 labels = c("Spring", "Summer", "Autumn", "Winter"))
136
137 boxplot(total_user ~ season_name,

```

```

138     data = data_group,
139     main = "Boxplot: Total Users per Season",
140     xlab = "Season",
141     ylab = "Total Users",
142     col = c("lightgreen", "orange", "yellow", "lightblue"))
143
144 dev.off()
145
146 # =====
147 # 2. Analyse system usage as a function of weather conditions.
148 # For each condition, calculate the mean and standard deviation
149 # of total_user, and determine the proportion of days classified as low_usage.
150 # Use appropriate statistical measures and plots to compare the weather conditions
151 # ("Clear", "Cloudy", "Light Rain", and "Heavy Rain").
152 # =====
153
154 cat("\n3.2 Per weather condition usage\n")
155 cat("\n First 10th verification")
156 cat("\n Weather Condition: clear \n")
157
158 data_g10_clear <- subset(data_g10, weathersit == 1)
159 clear_g10_total_users <- data_g10_clear$total_user
160
161 sum_10_clear <- sum(clear_g10_total_users)
162 n_10_clear <- length(clear_g10_total_users)
163 manual_mean_10clear <- sum_10_clear / n_10_clear
164
165 mean_10clear <- mean(clear_g10_total_users)
166 cat("    Manual mean = ", sum_10_clear, " / ", n_10_clear, " = ", mean_10clear, "\n", sep = "")
167
168 squared_deviations_10clear <- (clear_g10_total_users - manual_mean_10clear)^2
169 sum_sqr_dev_10clear <- sum(squared_deviations_10clear)
170 manual_variance_10clear <- sum_sqr_dev_10clear / (n_10_clear - 1)
171 manual_std_10clear <- sqrt(manual_variance_10clear)
172 cat("    Standard Deviation = ", manual_std_10clear, "\n", sep = "")
173
174 std_10clear <- sd(clear_g10_total_users)
175
176 # Added low usage for 10th clear
177 manual_prop_low_10clear <- sum(data_g10_clear$low_usage) / nrow(data_g10_clear)
178 prop_low_10clear <- mean(data_g10_clear$low_usage)
179
180 cat("\n    COMPARISONS")
181 cat("\n    Manual mean: ", manual_mean_10clear, " | R: ", mean_10clear, " | Difference: ",
182     ↪ abs(manual_mean_10clear - mean_10clear), "\n", sep = "")
183 cat("\n    Manual std: ", manual_std_10clear, " | R: ", std_10clear, " | Difference: ",
184     ↪ abs(manual_std_10clear - std_10clear), "\n", sep = "")
185 cat("\n    Manual low_usage: ", manual_prop_low_10clear, " | R: ", prop_low_10clear, " | Difference: ",
186     ↪ abs(manual_prop_low_10clear - prop_low_10clear), "\n", sep = "")
187
188 cat("\n Weather Condition: cloudy \n")
189
190 data_g10_cloudy <- subset(data_g10, weathersit == 2)
191 cloudy_g10_total_users <- data_g10_cloudy$total_user
192
193 sum_10_cloudy <- sum(cloudy_g10_total_users)
194 n_10_cloudy <- length(cloudy_g10_total_users)
195 manual_mean_10cloudy <- sum_10_cloudy / n_10_cloudy
196
197 mean_10cloudy <- mean(cloudy_g10_total_users)

```

```

195 cat("    Manual mean = ", sum_10_cloudy, " / ", n_10_cloudy, " = ", mean_10cloudy, "\n", sep = "")
196
197 squared_deviations_10cloudy <- (cloudy_g10_total_users - manual_mean_10cloudy)^2
198 sum_sqr_dev_10cloudy <- sum(squared_deviations_10cloudy)
199 manual_variance_10cloudy <- sum_sqr_dev_10cloudy / (n_10_cloudy - 1)
200 manual_std_10cloudy <- sqrt(manual_variance_10cloudy)
201 cat("    Standard Deviation = ", manual_std_10cloudy, "\n", sep = "")
202
203 std_10cloudy <- sd(cloudy_g10_total_users)
204
205 # Added low usage for 10th cloudy
206 manual_prop_low_10cloudy <- sum(data_g10_cloudy$low_usage) / nrow(data_g10_cloudy)
207 prop_low_10cloudy <- mean(data_g10_cloudy$low_usage)
208
209 cat("\n    COMPARISONS")
210 cat("\n    Manual mean: ", manual_mean_10cloudy, " | R: ", mean_10cloudy, " | Difference: ",
    ↪ abs(manual_mean_10cloudy - mean_10cloudy), "\n", sep = "")
211 cat("    Manual std: ", manual_std_10cloudy, " | R: ", std_10cloudy, " | Difference: ",
    ↪ abs(manual_std_10cloudy - std_10cloudy), "\n", sep = "")
212 cat("    Manual low_usage: ", manual_prop_low_10cloudy, " | R: ", prop_low_10cloudy, " | Difference: ",
    ↪ abs(manual_prop_low_10cloudy - prop_low_10cloudy), "\n", sep = "")
213
214 cat("\n All data_group")
215 cat("\n Weather Condition: CLEAR\n")
216
217 data_clear <- subset(data_group, weathersit == 1)
218 clear_total_users <- data_clear$total_user
219
220 mean_clear <- mean(clear_total_users)
221 std_clear <- sd(clear_total_users)
222 prop_low_clear <- mean(data_clear$low_usage)
223 cat("    n: ", length(clear_total_users), "\n", sep = "")
224 cat("    mean: ", mean_clear, "\n", sep = "")
225 cat("    std: ", std_clear, "\n", sep = "")
226 cat("    low_usage days: ", prop_low_clear, "\n", sep = "")
227
228 cat("\n Weather Condition: CLOUDY\n")
229
230 data_cloudy <- subset(data_group, weathersit == 2)
231 cloudy_total_users <- data_cloudy$total_user
232
233 mean_cloudy <- mean(cloudy_total_users)
234 std_cloudy <- sd(cloudy_total_users)
235 prop_low_cloudy <- mean(data_cloudy$low_usage)
236 cat("    n: ", length(cloudy_total_users), "\n", sep = "")
237 cat("    mean: ", mean_cloudy, "\n", sep = "")
238 cat("    std: ", std_cloudy, "\n", sep = "")
239 cat("    low_usage days: ", prop_low_cloudy, "\n", sep = "")
240
241
242 cat("\n Weather Condition: LIGHT RAIN\n")
243
244 data_light_rain <- subset(data_group, weathersit == 3)
245 light_rain_total_users <- data_light_rain$total_user
246
247 mean_light_rain <- mean(light_rain_total_users)
248 std_light_rain <- sd(light_rain_total_users)
249 prop_low_light_rain <- mean(data_light_rain$low_usage)
250 cat("    n: ", length(light_rain_total_users), "\n", sep = "")
251 cat("    mean: ", mean_light_rain, "\n", sep = "")

```

```

252 cat("      std: ", std_light_rain, "\n", sep = "")
253 cat("      low_usage days: ", prop_low_light_rain, "\n", sep = "")
254
255
256 cat("\n Weather Condition: HEAVY RAIN\n")
257
258 data_heavy_rain <- subset(data_group, weathersit == 4)
259 # Checked with na.rm = TRUE in case category 4 has 0 days
260 if(nrow(data_heavy_rain) > 0) {
261   heavy_rain_total_users <- data_heavy_rain$total_user
262   mean_heavy_rain <- mean(heavy_rain_total_users)
263   std_heavy_rain <- sd(heavy_rain_total_users)
264   prop_low_heavy_rain <- mean(data_heavy_rain$low_usage)
265
266   cat("      n: ", length(heavy_rain_total_users), "\n", sep = "")
267   cat("      mean: ", mean_heavy_rain, "\n", sep = "")
268   cat("      std: ", std_heavy_rain, "\n", sep = "")
269   cat("      low_usage days: ", prop_low_heavy_rain, "\n", sep = "")
270 } else {
271   cat("      No Heavy Rain days in the dataset.\n")
272 }
273
274 pdf(file = "/Users/fabiomachadomilan/Estatistica/Docs/assets/boxplot_weather.pdf", width = 7, height = 4.5)
275
276 # Plotting the Weather condition comparison
277 data_group$weather_name <- factor(data_group$weathersit,
278                                   levels = c(1, 2, 3, 4),
279                                   labels = c("Clear", "Cloudy", "Light Rain", "Heavy Rain"))
280
281 boxplot(total_user ~ weather_name,
282         data = data_group,
283         main = "Boxplot: Total Users per Weather",
284         xlab = "Weather Condition",
285         ylab = "Total Users",
286         col = c("#a6cee3", "#1f78b4", "#b2df8a", "#33a02c"))
287 dev.off()
288
289 # =====
290 # 3. Investigate the relationship between temperature and total_user.
291 # Construct a scatter plot and calculate the correlation coefficient.
292 # Interpret the direction and strength of the association and discuss possible
293 # limitations of the correlation coefficient in describing the observed relationship.
294 # =====
295 cat("\n3.3 Temperature vs Total Users Correlation\n")
296 cat("\n First 10th verification\n")
297
298 temp_10 <- data_g10$temp
299 users_10 <- data_g10$total_user
300 n_10 <- length(temp_10)
301
302 mean_temp_10 <- mean(temp_10)
303 mean_users_10 <- mean(users_10)
304
305 # Deviations from the mean
306 dev_temp_10 <- temp_10 - mean_temp_10
307 dev_users_10 <- users_10 - mean_users_10
308
309 sum_prod_10 <- sum(dev_temp_10 * dev_users_10)
310 sum_sq_temp_10 <- sum(dev_temp_10^2)
311 sum_sq_users_10 <- sum(dev_users_10^2)

```

```

312
313 # Manual Pearson correlation formula
314 manual_r_10 <- sum_prod_10 / sqrt(sum_sq_temp_10 * sum_sq_users_10)
315 r_10 <- cor(temp_10, users_10)
316
317 cat("    Manual r = ", manual_r_10, "\n", sep="")
318
319 cat("\n    COMPARATIONS\n")
320 cat("    Manual r: ", manual_r_10, " | R: ", r_10, " | Difference: ", abs(manual_r_10 - r_10), "\n", sep="")
321
322
323 cat("\n All data_group\n")
324 # Cor in R for the full dataset
325 r_all <- cor(data_group$temp, data_group$total_user)
326 cat("    Correlation coefficient (r) = ", r_all, "\n", sep="")
327
328 pdf(file = "/Users/fabiomachadomilan/Estatistica/Docs/assets/scatter_temp.pdf", width = 12, height = 9)
329
330 # Scatter plot for total_user vs Temperature
331 plot(data_group$temp, data_group$total_user,
332      pch = 19, col = "darkblue",
333      main = "Scatter Plot: Temperature vs. Total Users",
334      xlab = "Temperature", ylab = "Total Users")
335 dev.off()
336
337
338 # =====
339 # 4. Based on the analyses performed in this question,
340 # select two characteristics that appear to be most strongly
341 # associated with system usage. Justify your choice based on
342 # the statistical and/or graphical results.
343 # =====
344
345 cat("\n3.4 Final Feature Selection\n")
346 cat("\n My choice: Temperature and Weather Conditions.\n")
347 cat(" Reason: Linear correlation confirmed by 'r' and scatter plot. Boxplots show maximum values declining
348 ↪ when tending to rain, which makes a lot of sense since it is a bike system.\n")
349
350 pdf(file = "/Users/fabiomachadomilan/Estatistica/Docs/assets/boxplots_temp.pdf", width = 14, height = 4.5)
351 # Putting the final justification plots side-by-side
352 par(mfrow = c(1, 2))
353
354 # Plot A: Temperature by Season
355 boxplot(temp ~ season_name,
356        data = data_group,
357        main = "Temperature by Season",
358        xlab = "Season",
359        ylab = "Temperature",
360        col = c("lightgreen", "orange", "yellow", "lightblue"))
361
362 # Plot B: Temperature by Weather Condition
363 boxplot(temp ~ weather_name,
364        data = data_group,
365        main = "Temperature by Weather Condition",
366        xlab = "Weather Condition",
367        ylab = "Temperature",
368        col = c("#a6cee3", "#1f78b4", "#b2df8a", "#33a02c"))
369
370 par(mfrow = c(1, 1)) # Reset plot window
371 dev.off()

```

A.3 Script questão 4 (question4.R)

```
1 rm(list = ls()) #Cleaning environment
2 cat("\014")
3 options(digits = 4)
4
5 #instale os pacotes para rodar o código
6 #install.packages("fpp3")
7 #install.packages("rstudioapi")
8 library(fpp3)
9 library("rstudioapi")
10
11
12 #importando os dados que serão usado
13 k <- getSourceEditorContext()$path
14 setwd(dirname(k))
15 load(paste0("data_group.RData"))
16 data_g10 <- data_group[1:10, ]
17
18
19 cat("CHECando se os dados est?ão corretos\n")
20 cat("  > data_g10\n")
21 print(head(data_g10))
22 cat("\n > data_group\n")
23 print(tail(data_group))
24
25
26 cat("\n")
27 cat("Question 4: Análise bivariada\n", sep="")
28
29 # =====
30 # 1. Construa a serie temporal de total_user. Identifique perezos de maior e
31 # menor utilização e discuta os principais padroes observados
32 # =====
33
34 cat("4.1 - series temporais\n", sep="")
35
36 # transformando a coluna dteday de uma strig para um objeto que a função autoplot
37 # possa usar para criar a serie temporal.
38 # |> é o pipe, coloca a fun????o da esquerda como parametro da direita
39 # mutate cria a coluna data, com o tipo, date,
40 #select deleta a colunadteday
41 # as_tribble transforma o dataset em uma serie temporal
42 data_tempo = data_group
43
44 data_tempo <- data_tempo |>
45   mutate(day = as.Date(dteday)) |>
46   select(-dteday) |>
47   as_tsibble(index = day)
48
49 data_tempo
50
51 #plotando a serie temporal com a função autoplot, usando o dataset que é a nossa serie
52 #temporal e a variavel que queremos plotar, no caso, o total de usuários
53 # geomline controla o tamanho da linha da serie
54 # geom_smooth faz uma linha de tendendia para melhor visualização
55 autoplot(data_tempo, total_user)+
56   geom_line(linewidth = 1.2, linetype = "solid", alpha = 0.8)+
57   geom_smooth(method="loess", se = FALSE, linewidth = 1)+
58   labs(y = "total_user",x = "dia", title = "Serie temporal de uso de bicicletas ao longo dos dias")
```

```

59
60 autoplot(data_tempo, season)+
61   geom_line(linewidth = 1.2, linetype = "solid", alpha = 0.8)+
62   labs(y = "season", x = "dia", title = "Serie temporal de temporada")
63
64 cat(" observando o prot da serie temporal, em janeiro, come??a um periodo de pouco uso.
65 Por??m esse uso vai aumentando gradativamente at?? o seu apice em junho, no qual,
66 come??a a cair gradativamente até o final do ano.\n")
67
68 cat(" Isso provavelmente tem sua origem nas mudanças de temporadas, por que, como foi falado na quest??o 2
69 as temporadas determinam a temperatura, que tem uma correlação forte com a quantidade de usu??rios.
70     A exemplo que, no verão e outono , onde a temperatura é maior, a serie atinge o seu apice,
71     Já no inverno e na primavera, com temperaturas menores, ela atinge seu ponto mais baixo\n")
72
73
74
75 # =====
76 # 2. Retome as duas características selecionadas na Quest??o 3. Para cada uma, escolha
77 # uma visualização e uma medida estat??stica adequadas para analisar sua associa??o com
78 # total_user. Apresente e interprete os resultados, comparando-os com as conclus??es
79 # obtidas na Questão
80 # =====
81 cat("4.2 - analises das características selecionadas\n", sep="")
82
83 cat("as características escolhidas na questão 1 foram, temperatura como o fator que
84     determina o formato normal do total_user, e as condições atimosfericas, como fator
85     que limita os usu??rios caso chova")
86
87 #temperatura
88 cat("variavel 1 - temperatura\n", sep="")
89 cat("A proposta em questão é, a temperatura esta relacionada com os usuarios totais,
90     de uma forma não linear, mas que, na região das amostras, tende a ser linear. PPara
91     comprovar isso, poderia por exemplo, plotamos as linhas de tendencia, como na figura 2.
92     Em vermelho é a tendencia não linear que mais se adapta a nuvem de pontos, ja em verde
93     est?? a tendencia linear, da nuvem de pontos. A regia??o em cinza ?? um intervalo de confian??a
94     com aproximadamente 5% de erro.\n")
95
96
97 #plotando o grafico de dispersão com ggplot
98 #geom_point diz que ?? um grafico de dispersão com os pontos de tamanho 2
99 #geom_smoth cria a linha de tendencia, lm para linear, e loess para se adaptar aos pontos
100 ggplot(data = data_group, mapping = aes(x=temp, y=total_user)) +
101   geom_point(size = 2) +
102   geom_smooth(method = "lm", color = "green") +
103   geom_smooth(method = "loess", color = "red") +
104   labs(title = "total_user em função da temperatura e condição de chuva")
105
106
107 cat("as medidas que mais nos d??o informa??es uteis para confirmar essa hip??tese s??o
108     a correla??o de pearson ja calculada na quest??o 3 e a de sperman.\n")
109 #a medida de pearman avalia a rela??o monot??nica entre duas vari??veis cont??nuas ou ordinais.
110 #Em uma rela??o monot??nica, as vari??veis tendem a mudar juntas mas n??o necessariamente a uma
111 #taxa constante.O coeficiente de correla??o de Spearman baseia-se nos valores classificados
112 #de cada vari??vel, em vez de os dados brutos.
113 #Ou se o aumento ?? puramente linear, ambos os coeficientes ser??o 1.
114 #se uma variavel aumenta quando a outra aumenta, mas sem ser consistente, person ser?? positivo, mas
115 #menor que 1, e sperman ser?? 1.
116 #por??m, se a rela??o for n??o linear de forma que em uma parte esteja subindo e em outra descendo,
117   ↪ ambos tendem a ir para 0
118 sperman <- cor.test(x=data_group$temp, y=data_group$total_user, method = 'spearman', exact = FALSE)

```

```

118 pearson <- cor.test(x=data_group$temp, y=data_group$total_user, method = 'pearson', exact = FALSE)
119
120 cat("sperman: ", sperman$estimate, sep=" ")
121 cat("pearson: ", pearson$estimate, sep=" ")
122
123 cat("\nAqui, uma percepção que podemos ter, com o coeficiente de Sperman sendo menor que o
124     de pearson ?? que a nuvem segue uma tendencia linear forte de aumento, porem, em algum ponto
125     essa tendendoa muda, o que abaixa o coeficiente de Sperman, o que ?? muito perceptivel na
126     ↪ visualizaçãodo do grafico.\n")
127
128 #wheaater condition
129 cat("variavel 2 - clima\n", sep="")
130
131 #figura 3
132 cat("com essa condiçãoo, estamos querendo confirmar a hipótese de que a chuva é um fator limitante
133     na correlação ente a temperatura e a quantidade de usuários.\n")
134
135 cat("aqui, dois graficos podem nos trazer informações importantes. O primeiro, figura 3, sendo
136     uma variação do anterior, nos da a visualizção da classe weathersit na disperção.
137     Nesse grafico, é possivel observar que todas as amostras de classes com chuva, apresentam
138     uma variação maior da tendendcia dos pontos")
139
140 #grafico de disperçãoo separado por classes
141 #mesmo do anterior, mas as.factor() diz nossas classes e
142 #scale_color_manual, edita as cores e legendas delas
143 ggplot(data = data_group, mapping = aes(x=temp, y=total_user, colour = as.factor(weathersit))) +
144     geom_point(size = 2) +
145     geom_smooth(method = "lm", color = "green") +
146     geom_smooth(method = "loess", color = "red") +
147     scale_color_manual(values = c("purple", "black", "orange", "red"), labels = c("clear", "cloudy", "light
148     ↪ Rain", "Heavy Rain"))+
149     labs(title = "total_user em função da temperatura e condição de chuva")
150
151 #figura 4
152 cat("essa premissa pode ser melhor observada no grafico 4, que resalta a diferença nas medias
153     observadas entre cada faixa de temperatura, sendo, frio abaixo de 15, normal, entre 15 e 25,
154     e quente maior que 25. As medias são as medidas estatisticas usadas para comparaçãoo
155     entre as classes nas temperaturas correspondentes.\n")
156
157 #criando as categorias de temperatura r clima
158 data_group$temp_cls <- ifelse(data_group$temp < 15, 0, ifelse(data_group$temp < 25, 1,2))
159 data_group$temp_cls <- factor(data_group$temp_cls,
160                               levels = c(0, 1, 2),
161                               labels = c("frio", "normal", "quente"))
162 data_group$weather_name <- factor(data_group$weathersit,
163                                   levels = c(1, 2, 3, 4),
164                                   labels = c("Clear", "Cloudy", "Light Rain", "Heavy Rain"))
165
166 #obtendo as medias gerais
167 #mutate cria nossas colunas
168 #sumarise resume nossos dados
169 #groupy_by separa em classes, e grupo ?? a nossa coluna de grupos
170 media_geral <- mutate(
171     summarise(
172         group_by( data_group, temp_cls),
173         media = mean(total_user, na.rm = TRUE)),
174     grupo = "Geral")
175
176 #obtendo as medias de cada classe de clima

```

```

176 media_wheater <-select(
177   mutate(
178     summarise(
179       group_by(data_group, temp_cls, weather_name),
180       media = mean(total_user, na.rm = TRUE),
181       .groups = "drop"),
182     grupo = as.character(weather_name)),
183   temp_cls,
184   media,
185   grupo)
186
187 # juntando ambas
188 medias <- bind_rows(
189   media_geral,
190   media_wheater
191 )
192
193 #ordenando
194 medias = arrange(medias, temp_cls)
195 medias
196
197 #plotando o grafico de colunas
198 #fill=grupos separa nossos grupos
199 #com um processamento anterior, ver no apendice A
200 ggplot(data = medias, mapping = aes(x=temp_cls, y=media, fill=grupo)) +
201   geom_col(position = position_dodge()) +
202   labs(title = "total_user por classe de temperatura",
203        x="temperatura por classes",
204        y="medias total_user") +
205   theme_bw()
206
207
208
209
210 # =====
211 # 3. Aprofunde a análise da relação entre temperatura e total_user, diferenciando
212 #visualmente os dias classificados como low_usage dos restantes. Discuta os principais
213 #padrões observados e avalie se a relação entre temperatura e utilização parece diferir
214 #entre os grupos
215 # =====
216 cat("4.3 - analise pela classe Low_Usage\n", sep="")
217
218
219 #novamente, utilizando a função, ggplot para plotar um grafico de dispersão separado por classes
220 ggplot(data = data_group, mapping = aes(x=temp, y=total_user, colour = as.factor(low_usage))) +
221   geom_point(size = 2) +
222   geom_smooth(method = "loess", color = "red") +
223   scale_color_manual(values = c("violet", "brown"), labels = c("Normal", "Low_uSAGE"))+
224   labs(title = "total_user em função da temperatura e condição de chuva")
225
226 cat("como Low usage já é uma variavel derivada de total_user, as amostras que estão abaixo
227     no grafico acabam sendo de low_usage 1, já as de cima, low_usage 0. é notorio que, como
228     a tendencia do grafico é ter mais usuarios conforme a temperatura, a concentração de low_usage
229     está principalmente em temperaturas menores.")

```

Referências

KERNS, G. J. *Introduction to Probability and Statistics Using R*. 1. ed. Ypsilanti, MI: G. Jay

Kerns, 2010.

MAGALHAES, D. S. T.; MILAN, G. G. R.; SEABRA, G. O. *Repositório do Homework 1 de Estatística para Engenharia (TI0111)*. [S.l.]: GitHub, 2026. <<https://github.com/gustii17/Estatistica>>. Acesso em: 27 set. 2026.

MULAS, M. *TI0111-2026.2-L01_freq_distib (notes on slides)*. Fortaleza: Universidade Federal do Ceará, 2026. Apresentação de slides. Disciplina de Estatística para Engenharia (TI0111). Material didático não publicado.

MULAS, M. *TI0111-2026.2-L04_wrap_descriptive_stats (notes on slides)*. Fortaleza: Universidade Federal do Ceará, 2026. Apresentação de slides. Disciplina de Estatística para Engenharia (TI0111). Material didático não publicado.

MULAS, M. *TI0111_HW1_assignment*. Fortaleza: Universidade Federal do Ceará, 2026. Instruções do Homework 1. Disciplina de Estatística para Engenharia (TI0111). Material didático não publicado.

ROSS, S. M. *Introduction to Probability and Statistics for Engineers and Scientists*. 6. ed. San Diego, CA: Academic Press, 2020.