



UNIVERSIDADE FEDERAL DO CEARÁ
DEPARTAMENTO DE ENGENHARIA DE TELEINFORMÁTICA
TI0111 - ESTATÍSTICA PARA ENGENHARIA
SEMESTRE 2026.2

DAVI SOUSA TRE VIA MAGALHAES (554934)
GIOVANNI GABRIEL REMEDY MILAN (578412)
GUSTAVO OLIVEIRA SEABRA (567464)

HOMEWORK 1 - ESTATÍSTICA DESCRITIVA
BIKE SHARING DATASET

FORTALEZA – CE
SETEMBRO, 2026

Índice

INTRODUÇÃO	2
1 QUESTÃO 1:	2
2 QUESTÃO 2:	2
3 QUESTÃO 3: Análise dos dias de menor utilização	2
3.1 Utilização do sistema por estação do ano	2
3.2 Utilização do sistema por condições meteorológicas	4
3.3 Relação entre temperatura e utilização diária	6
3.4 Seleção das características mais associadas à utilização	8
4 QUESTÃO 4:	9
CONCLUSÃO	9
APÊNDICES	10
A CÓDIGO FONTE EM R UTILIZADO NAS ANÁLISES	10
A.1 Script questões 1 e 2 (main.R)	10
A.2 Script questão 3 (question3.R)	14

INTRODUÇÃO

Como Ross introduz, "in today's world that in order to learn about something you must first collect data. Statistics is the art of learning from data. It is concerned with the collection of data, its subsequent description, and its analysis, which often leads to the drawing of conclusions"(ROSS, 2020). Nesse sentido a estatística descritiva é a ferramenta primeira que permite a compreensão dos dados coletados, e por consequência dos fenômenos que eles representam, sendo definida como "the way to quantitatively describe/summarise a collection of information"(MULAS, 2026a). Para isso, tabelas e gráficos são "particularly useful ways of presenting data, often revealing important features such as the range, the degree of concentration, and the symmetry of the data"(ROSS, 2020).

A fim de "revisar e se familiarizar com os conceitos de estatística descritiva"(MULAS, 2026c), o objetivo é aplicar esses conceitos na análise de um sistema de compartilhamento de bicicletas localizado nos Estados Unidos. O conjunto de dados original, *HWI_bike_sharing.csv*, contém observações diárias referentes às condições meteorológicas, estações do ano e o volume de usuários do sistema.

1 QUESTÃO 1:

2 QUESTÃO 2:

3 QUESTÃO 3: ANÁLISE DOS DIAS DE MENOR UTILIZAÇÃO

Nesta questão, investigam-se as condições do clima e da estação do ano associadas aos dias de baixa utilização do sistema a partir da variável `low_usage` definida anteriormente (Seção 2).

3.1 Utilização do sistema por estação do ano

A fim de analisar o impacto da sazonalidade no uso do sistema de compartilhamento de bicicletas, a amostra de 300 dias foi agrupada pelas quatro estações do ano (*season*). Para cada subconjunto, extraíram-se o tamanho da amostra (n), a média amostral ($\bar{x}$), a mediana ($\tilde{x}$), o desvio padrão amostral (s) e a proporção de dias classificados como de baixa utilização (p_{low}).

A extração dessas métricas foi realizada computacionalmente por meio da linguagem R, isolando-se os subconjuntos lógicos e aplicando as funções descritivas nativas, conforme ilustrado no Código 1 e os resultados obtidos foram resumidos na Tabela 1.

```

71 data_spring <- subset(data_group, season == 1)
72 spring_total_users <- data_spring$total_user
73 mean_spring <- mean(spring_total_users)
74 median_spring <- median(spring_total_users)
75 std_spring <- sd(spring_total_users)
76 prop_low_spring <- mean(data_spring$low_usage)

```

Listing 1 – Trecho do script em R para o cálculo descritivo por estação (exemplo da primavera).

Tabela 1 – Indicadores estatísticos do volume de usuários categorizados por estação do ano.

Estação	n	$\bar{x}$	M_e	s	p_{low} (%)
1 (Primavera)	67	1682	1650	579	86.57
2 (Verão)	92	3775	4086	1139	14.13
3 (Outono)	94	4464	4616	798.3	3.19
4 (Inverno)	47	4067	4187	986.1	2.13

Nota: n = tamanho do subgrupo; $\bar{x}$ = média amostral; M_e = mediana; s = desvio padrão amostral; p = proporção de dias (*low_usage*).

Comparando-se os valores da Tabela 1, fica evidente algumas discrepâncias no comportamento dos usuários ao longo das estações. A primavera destaca-se como o período de menor demanda no sistema, registrando uma média de $\bar{x} = 1682$ usuários e uma mediana de $M_e = 1650$, valores inferiores à metade dos observados nas demais estações. Consequentemente, a proporção de dias de baixa utilização na primavera alcança expressivos 86,57%, evidenciando uma restrição severa ao uso do serviço neste período.

Em contrapartida, o outono e o inverno exibem os maiores patamares de movimentação, com médias de $\bar{x} = 4464$ e $\bar{x} = 4067$ usuários, respectivamente. Inclusive o outono concentra a maior mediana da amostra ($M_e = 4616$) e a menor incidência de dias de baixa utilização ($p = 3,19\%$). Já o verão, embora apresente um volume substancial de usuários ($\bar{x} = 3775$), manifesta maior dispersão interna ($s = 1139$), o que se reflete em uma faixa interquartil mais ampla.

O *boxplot* (Figura 1) corrobora os valores da Tabela 1. Nota-se que a caixa da primavera está isolada na base do gráfico, sem sobreposição com as demais distribuições, além de apresentar *outliers* superiores e inferiores. Para as estações de Verão, Outono e Inverno, as medianas posicionam-se em patamares acima de 4000 usuários. O outono apresenta uma caixa mais compacta, indicando menor dispersão, e *outliers* superiores e inferiores. Enquanto isso, o verão exibe a caixa mais ampla e os maiores *whiskers* sem nenhum *outlier*, refletindo a maior variabilidade interna, e o inverno apresenta uma caixa intermediária, com *outliers* superiores.




Figura 1 – Boxplot comparativo do total de usuários por estação do ano.

Do ponto de vista prático, tais variações demonstram que estações mais secas (como verão, outono e inverno) influenciam diretamente a atratividade do transporte de bicicletas.

3.2 Utilização do sistema por condições meteorológicas

Em complemento à análise sazonal, investigou-se a variação no volume de usuários do sistema em função das condições meteorológicas (*weathersit*). Para cada categoria climática registrada na amostra de 300 dias, computaram-se o tamanho do subgrupo (n), a média amostral ($\bar{x}$), o desvio padrão amostral (s) e a proporção de dias classificados como de baixa utilização (p_{low}).

O procedimento computacional para a extração dessas métricas e filtragem das condições de céu limpo, nublado, chuva leve e chuva forte seguiu a mesma lógica de subconjuntos lógicos em R, conforme exemplificado no Código 2.

```

215 data_clear <- subset(data_group, weathersit == 1)
216 clear_total_users <- data_clear$total_user
217
218 mean_clear <- mean(clear_total_users)
219 std_clear <- sd(clear_total_users)
220 prop_low_clear <- mean(data_clear$low_usage)

```

Listing 2 – Trecho do script em R para o cálculo descritivo por condição meteorológica (exemplo do clima limpo).

Os resultados estatísticos obtidos para cada condição climática encontram-se resumidos na Tabela 2. Destaca-se que a categoria de chuva forte (*Heavy Rain*) não registrou ocorrências no período amostral de 300 dias analisado.

Tabela 2 – Indicadores estatísticos do volume de usuários categorizados por condição meteorológica.

Condição Meteorológica	n	$\bar{x}$	s	p_{low} (%)
1 (Céu Limpo)	186	3899	1305	18.28
2 (Nublado)	104	3173	1304	32.69
3 (Chuva Fraca)	10	1562	851.9	70.00
4 (Chuva Forte)	0	–	–	–

Nota: n = tamanho do subgrupo; $\bar{x}$ = média amostral; s = desvio padrão amostral; p_{low} = proporção de dias (*low_usage*).

A análise dos dados evidencia uma forte degradação na atratividade do serviço conforme as condições climáticas se tornam chuvosas. A maior parte dos registros concentra-se sob a condição de céu limpo ($n = 186$ dias), apresentando o maior patamar médio de utilização ($\bar{x} = 3899$ usuários) e a menor incidência de dias de baixa demanda ($p = 18,28\%$).

Sob condições nubladas, observa-se uma redução moderada na média de usuários ($\bar{x} = 3173$), acompanhada por um aumento expressivo na proporção de baixa utilização, que passa a atingir 32,69%. No entanto, o impacto mais drástico ocorre em dias de chuva fraca ($n = 10$). Embora representem uma fração minoritária da amostra, a média de usuários desaba para $\bar{x} = 1562$ (menos da metade de um dia limpo), e a proporção de dias classificados como de baixa utilização salta para 70,00%.

O *boxplot* (Figura 2) corrobora visualmente esses valores. Observa-se que a distribuição do total de usuários sob céu limpo possui sua mediana posicionada no terço superior do gráfico, com a maior amplitude de valores normais e apenas um *outlier* inferior. Conforme o clima transita para a chuva fraca, nota-se um deslocamento progressivo das caixas para patamares inferiores de utilização, acompanhado por uma compressão na dispersão dos dados nos dias chuvosos devido ao baixo volume de operações.




Figura 2 – Boxplot comparativo do total de usuários por condição meteorológica.

Dessa forma, os dados demonstram que o comportamento aparentemente inesperado observado nas estações do ano (onde períodos de outono e inverno registraram volumes elevados de demanda) encontra sua principal justificativa nas condições meteorológicas. Isso indica que a disposição dos usuários em utilizar o sistema é governada de forma muito mais direta pela presença de precipitação e cobertura de nuvens do que estritamente pela sazonalidade.

3.3 Relação entre temperatura e utilização diária

Para investigar a relação entre a temperatura ambiente (*temp*) e o volume diário de locações (*total_user*), ambas variáveis quantitativas contínuas, adotou-se o Coeficiente de Correlação Amostral de Pearson (r). O coeficiente r quantifica a força e a direção da associação linear entre duas variáveis, variando no intervalo $[-1, 1]$ (ROSS, 2020).

Para fins de validação, o cálculo foi primeiramente estruturado de forma manual para as 10 primeiras observações da amostra, computando-se os desvios em relação à média, a soma dos produtos dos desvios (covariância não normalizada) e as somas dos quadrados (variâncias não normalizadas). Posteriormente, o resultado foi confrontado com a função nativa `cor()` do R. O Código 3 exibe a implementação deste procedimento.

```

293 cat("\n3.3 Temperature vs Total Users Correlation\n")
294 cat("\n First 10th verification\n")
295
296 temp_10 <- data_g10$temp
297 users_10 <- data_g10$total_user
298 n_10 <- length(temp_10)
299
300 mean_temp_10 <- mean(temp_10)
301 mean_users_10 <- mean(users_10)
302
303 # Deviations from the mean
304 dev_temp_10 <- temp_10 - mean_temp_10
305 dev_users_10 <- users_10 - mean_users_10
306
307 sum_prod_10 <- sum(dev_temp_10 * dev_users_10)
308 sum_sq_temp_10 <- sum(dev_temp_10^2)
309 sum_sq_users_10 <- sum(dev_users_10^2)
310
311 # Manual Pearson correlation formula
312 manual_r_10 <- sum_prod_10 / sqrt(sum_sq_temp_10 * sum_sq_users_10)
313 r_10 <- cor(temp_10, users_10)
314
315 cat("   Manual r = ", manual_r_10, "\n", sep="")
316
317 cat("\n   COMPARATIONS\n")
318 cat("   Manual r: ", manual_r_10, " | R: ", r_10, " | Difference: ", abs(manual_r_10 -
  → r_10), "\n", sep="")
319
320
321 cat("\n All data_group\n")
322 # Cor in R for the full dataset
323 r_all <- cor(data_group$temp, data_group$total_user)
324 cat("   Correlation coefficient (r) = ", r_all, "\n", sep="")

```

Listing 3 – Trecho do script em R para o cálculo manual e automatizado da correlação de Pearson.

A validação no subconjunto de 10 amostras retornou um coeficiente $r \approx 0,4414$. A comparação entre o cálculo desenvolvido passo a passo e o executado pela função interna do R revelou uma diferença residual de $5,551 \times 10^{-17}$. Cumpre ressaltar que esta discrepância pequena não configura um erro metodológico, mas sim um erro de arredondamento inerente à precisão de ponto flutuante da própria linguagem (KERNS, 2010).

Ao escalar o cálculo para a amostra completa ($n = 300$), obteve-se um coeficiente de correlação $r = 0,7839$. Segundo Ross e os slides da disciplina (ROSS, 2020; MULAS, 2026b), valores de $|r|$ próximos a 0,8 indicam uma associação linear positiva de intensidade forte. Isso significa que, em termos globais, o aumento da temperatura ambiente está fortemente associado ao aumento no número de bicicletas alugadas.




Figura 3 – Diagrama de dispersão evidenciando a associação linear positiva entre a temperatura real (°C) e o total de usuários.

A análise visual do diagrama de dispersão (Figura 3) confirma a natureza positiva e proporcional da relação. Observa-se uma nuvem de pontos com clara tendência ascendente à medida que a temperatura avança dos 5°C em direção aos 25°C.

Contudo, a inspeção gráfica também evidencia as limitações da correlação linear estrita: ao atingir temperaturas extremas (próximas ou superiores a 30°C), a tendência de crescimento cessa e a nuvem de pontos aparenta estabilizar ou declinar levemente. Tal comportamento sugere a existência de um ponto de saturação de conforto térmico, a partir do qual o calor excessivo passa a desencorajar atividades físicas ao ar livre.

3.4 Seleção das características mais associadas à utilização

Com base nas análises exploratórias conduzidas nas subseções anteriores, selecionaram-se a temperatura (*temp*) e as condições meteorológicas (*weathersit*) como as duas características que exercem a maior influência sobre a demanda do sistema de compartilhamento de bicicletas.

A escolha da temperatura justifica-se quantitativamente pelo forte coeficiente de correlação linear positivo ($r = 0,7839$) e pela evidência visual do diagrama de dispersão (Figura 3), demonstrando que o conforto térmico é um impulsionador contínuo para o uso do sistema. Por sua vez, as condições meteorológicas atuam como um fator restritivo categórico diário: a ocorrência de precipitação deprime drasticamente a média de locações e eleva a probabilidade de baixa utilização para 70%, conforme a Tabela 2.

Para complementar a dinâmica dessas variáveis, elaborou-se um *boxplot* duplo comparando a distribuição da temperatura em relação à sazonalidade e ao clima (Figura 4).




Figura 4 – Painel comparativo da distribuição de temperatura pelas estações do ano e condições meteorológicas.

A inspeção do painel direito da Figura 4 revela que as temperaturas máximas apresentam um declínio visível à medida que o clima transita para cenários de chuva. Concomitantemente, o painel esquerdo expõe a forte segmentação térmica imposta pela sazonalidade, onde a primavera concentra as temperaturas mais baixas e o outono as mais altas da amostra analisada.

Sob a ótica da mobilidade urbana, esses resultados comprovam que a dinâmica do sistema é otimamente modelada pelo par *Temperatura* e *Clima*: a temperatura fornece a escala contínua de atratividade térmica, enquanto o clima atua como um limitador imediato (presença ou ausência de chuva).

4 QUESTÃO 4:

CONCLUSÃO

APÊNDICES

A CÓDIGO FONTE EM R UTILIZADO NAS ANÁLISES

Os códigos a seguir apresentam o código-fonte completo desenvolvido em R para a execução de todas as etapas estatísticas e gráficas deste relatório disponível no repositório (MAGALHAES; MILAN; SEABRA, 2026). Os scripts são totalmente funcionais e executáveis, tendo sido desenvolvidos segundo a Tabela 3.

Tabela 3 – Scripts em R utilizados para cada questão do relatório.

Membro	Questão	Script em R
Davi S. T. Magalhães	1 e 2	main.R
Giovanni G. R. Milan	3	question3.R
Gustavo O. Seabra	4	-

A.1 Script questões 1 e 2 (main.R)

```
1 # Matrículas: 554934, 546474, 578412
2
3 rm(list = ls())
4 options(digits = 4)
5
6 # Carrega o dataset original
7 folder_path <- "/Users/fabiomachadomilan/Estatistica/codigos/Homework_1/"
8 dados_originais <- read.csv(paste0(folder_path, "HW1_bike_sharing.csv"), row.names = 1)
9
10 # Questão 1
11 cat("\n")
12 cat("\nQuestão 1: Construção do dataset\n")
13
14 # Números de matrícula do grupo
15 matriculas <- c(554934, 546474, 578412)
16
17 cat("\nInformações do Grupo\n")
18 cat("Números de matrícula: ", matriculas, "\n")
19
20 # Calcula M e r
21 M <- max(matriculas)
22 cat("Maior número de matrícula (M): ", M, "\n")
23
24 r <- 1 + (M %% 100)
25 cat("r = 1 + (M mod 100) = 1 + (", M, " mod 100) = ", r, "\n", sep = "")
26
27 # Seleciona 300 observações consecutivas
28 data_group <- dados_originais[r:(r+299), ] #[GGRM] + 300 estava selecionando no final 301, ajustei isso
29 #View(data_group)
30
31 cat("\n Amostra do Grupo \n")
32 cat("Dimensões de data_group: ", nrow(data_group), " x ", ncol(data_group), "\n", sep = "")
33 cat("Primeira data: ", as.character(data_group$dteday[1]), "\n", sep = "")
34 cat("Última data: ", as.character(data_group$dteday[nrow(data_group)]), "\n", sep = "")
35
```

```

36 cat("\nPrimeiras 10 observações de data_group:\n")
37 print(head(data_group, 10))
38
39
40 # PRIMEIRAS 10 OBSERVAÇÕES
41 cat("\n")
42 cat("As Primeiras 10 Observações\n")
43
44 dados_10 <- data_group[1:10, ]
45 dados_10$total_user <- dados_10$casual + dados_10$registered
46 total_user_10 <- dados_10$total_user
47
48 cat("\nValores de total_user (primeiras 10):\n")
49 print(total_user_10)
50
51 # MÉDIA
52 cat("\n Média \n")
53 soma <- sum(total_user_10)
54 n <- length(total_user_10)
55 media_manual <- soma / n
56 cat("Média = ", soma, " / ", n, " = ", media_manual, "\n", sep = "")
57
58 # MEDIANA
59 cat("\nMediana\n")
60 total_user_10_ordenado <- sort(total_user_10)
61 cat("Valores ordenados: ", total_user_10_ordenado, "\n", sep = " ")
62 mediana_manual <- (total_user_10_ordenado[5] + total_user_10_ordenado[6]) / 2
63 cat("Mediana = (", total_user_10_ordenado[5], " + ", total_user_10_ordenado[6], ") / 2 = ",
    ↪ mediana_manual, "\n", sep = "")
64
65 # DESVIO PADRÃO
66 cat("\nDesvio Padrão\n")
67 desvios_quadrados <- (total_user_10 - media_manual)^2
68 soma_dev_quad <- sum(desvios_quadrados)
69 variancia_manual <- soma_dev_quad / (n - 1)
70 desvio_padrao_manual <- sqrt(variancia_manual)
71 cat("Desvio Padrão = ", desvio_padrao_manual, "\n", sep = "")
72
73 # QUANTIS
74 cat("\nQuantis\n")
75 q1_pos <- (n + 1) * 0.25
76 q3_pos <- (n + 1) * 0.75
77 q1_idx_lower <- floor(q1_pos)
78 q1_idx_upper <- ceiling(q1_pos)
79 q1_frac <- q1_pos - floor(q1_pos)
80 q1_manual <- total_user_10_ordenado[q1_idx_lower] + q1_frac * (total_user_10_ordenado[q1_idx_upper] -
    ↪ total_user_10_ordenado[q1_idx_lower])
81
82 q3_idx_lower <- floor(q3_pos)
83 q3_idx_upper <- ceiling(q3_pos)
84 q3_frac <- q3_pos - floor(q3_pos)
85 q3_manual <- total_user_10_ordenado[q3_idx_lower] + q3_frac * (total_user_10_ordenado[q3_idx_upper] -
    ↪ total_user_10_ordenado[q3_idx_lower])
86
87 cat("Q1 = ", q1_manual, "\n", sep = "")
88 cat("Q2 = ", mediana_manual, "\n", sep = "")
89 cat("Q3 = ", q3_manual, "\n", sep = "")
90 cat("IQR = ", q3_manual - q1_manual, "\n", sep = "")
91
92 # VERIFICAÇÃO COM R

```

```

93 cat("\n")
94 cat("Verificação com R das primeiras 10 observações\n")
95
96 media_r <- mean(total_user_10)
97 mediana_r <- median(total_user_10)
98 desvio_r <- sd(total_user_10)
99
100 cat("\nMédia - Manual: ", media_manual, " | R: ", media_r, " | Diferença: ", abs(media_manual - media_r),
    ↪ "\n", sep = "")
101 cat("Mediana - Manual: ", mediana_manual, " | R: ", mediana_r, "\n", sep = "")
102 cat("Desvio Padrão - Manual: ", desvio_padrao_manual, " | R: ", desvio_r, "\n", sep = "")
103
104 # QUESTÃO 2
105 cat("\n")
106 cat("Questão 2: Caracterização do Dataset\n")
107
108 # Define total_user para todo o data_group
109 data_group$total_user <- data_group$casual + data_group$registered
110
111 # 2.1
112 cat("\n2.1 Classificação das variáveis\n")
113 cat("\nCategorias de SEASON:\n")
114 print(table(data_group$season))
115 cat("\nCategorias de WEATHERSIT:\n")
116 print(table(data_group$weathersit))
117 cat("\nValores ausentes:\n")
118 print(colSums(is.na(data_group)))
119
120 # 2.2
121 cat("\n\n2.2 Medidas de Tendência Central\n")
122 variaveis_numericas <- c("temp", "casual", "registered", "total_user")
123
124 for (var in variaveis_numericas) {
125   cat("\n", var, ":\n", sep = "")
126   media <- mean(data_group[[var]], na.rm = TRUE)
127   mediana <- median(data_group[[var]], na.rm = TRUE)
128   cat(" Média: ", round(media, 4), "\n", sep = "")
129   cat(" Mediana: ", round(mediana, 4), "\n", sep = "")
130   if (media > mediana) {
131     cat(" Assimetria: Positiva\n")
132   } else if (media < mediana) {
133     cat(" Assimetria: Negativa\n")
134   }
135 }
136
137 # 2.3
138 cat("\n\n2.3 Quartis e Intervalo Interquartil\n")
139 cat("\nVariável analisada: total_user\n")
140
141 total_user <- data_group$total_user
142
143 q1 <- quantile(total_user, probs = 0.25)
144 q2 <- quantile(total_user, probs = 0.50)
145 q3 <- quantile(total_user, probs = 0.75)
146 iqr <- q3 - q1
147
148 cat("\nQ1 = ", q1, "\n", sep = "")
149 cat("Q2 = ", q2, "\n", sep = "")
150 cat("Q3 = ", q3, "\n", sep = "")
151 cat("IQR = ", iqr, "\n", sep = "")

```

```

152
153   lim_inf <- q1 - 1.5 * iqr
154   lim_sup <- q3 + 1.5 * iqr
155
156   cat("\nLimites para outliers:\n")
157   cat("   Inferior: ", lim_inf, "\n", sep = "")
158   cat("   Superior: ", lim_sup, "\n", sep = "")
159
160   outliers <- which(total_user < lim_inf | total_user > lim_sup)
161   n_outliers <- length(outliers)
162
163   cat("\nNúmero de outliers: ", n_outliers, " (", round(n_outliers / nrow(data_group) * 100, 2), "%)\n",
164       ↪ sep = "")
165
166   # 2.4 Gráficos
167   cat("\n\n2.4 Gráficos\n")
168
169   par(mfrow = c(1, 2), mar = c(4, 4, 2, 2))
170
171   # Histograma
172   hist(total_user,
173        main = "Histograma: Total de Usuários",
174        xlab = "Total de Usuários",
175        ylab = "Frequência",
176        col = "steelblue",
177        breaks = 30)
178   abline(v = q1, col = "red", lty = 2, lwd = 2)
179   abline(v = q2, col = "green", lty = 2, lwd = 2)
180   abline(v = q3, col = "orange", lty = 2, lwd = 2)
181   legend("topleft", c("Q1", "Q2", "Q3"), col = c("red", "green", "orange"), lty = 2)
182
183   # Boxplot
184   boxplot(total_user, main = "Boxplot: Total de Usuários", ylab = "Total de Usuários", col = "steelblue")
185
186   par(mfrow = c(1, 1))
187
188   # Medidas de forma
189   skewness_val <- mean((total_user - mean(total_user))^3) / sd(total_user)^3
190   kurtosis_val <- mean((total_user - mean(total_user))^4) / sd(total_user)^4 - 3
191
192   cat("\nMedidas de forma:\n")
193   cat("   Assimetria: ", round(skewness_val, 4), "\n", sep = "")
194   cat("   Curtose: ", round(kurtosis_val, 4), "\n", sep = "")
195
196   # 2.5
197   cat("\n\n2.5 Variável low_usage\n")
198
199   data_group$low_usage <- ifelse(data_group$total_user < q1, 1, 0)
200
201   n_low <- sum(data_group$low_usage)
202   prop_low <- mean(data_group$low_usage)
203
204   cat("\nQ1 = ", q1, "\n", sep = "")
205   cat("Dias com baixa utilização: ", n_low, "\n", sep = "")
206   cat("Proporção: ", round(prop_low * 100, 2), "%\n", sep = "")
207
208   cat("\nTabela de frequência:\n")
209   print(table(data_group$low_usage))
210
211   # SALVAR

```

```

211 write.csv(data_group, file = "data_group.csv", row.names = FALSE)
212 save(data_group, file = "data_group.RData")
213
214 # RESUMO
215 cat("\n")
216 cat("Resumo Final\n")
217
218 cat("\nGrupo:\n")
219 cat(" Matrículas: ", paste(matriculas, collapse = ", "), "\n", sep = "")
220 cat(" M = ", M, "\n", sep = "")
221 cat(" r = ", r, "\n", sep = "")
222 cat(" Período: ", as.character(data_group$dteday[1]), " a ",
  ↪ as.character(data_group$dteday[nrow(data_group)]), "\n", sep = "")
223 cat(" Observações: ", nrow(data_group), "\n", sep = "")
224
225 cat("\nEstatísticas de total_user:\n")
226 cat(" Média: ", round(mean(total_user), 2), "\n", sep = "")
227 cat(" Mediana: ", round(median(total_user), 2), "\n", sep = "")
228 cat(" Q1: ", round(q1, 2), "\n", sep = "")
229 cat(" Q3: ", round(q3, 2), "\n", sep = "")
230 cat(" IQR: ", round(iqr, 2), "\n", sep = "")
231 cat(" Desvio Padrão: ", round(sd(total_user), 2), "\n", sep = "")
232
233 cat("\nVariavel low_usage:\n")
234 cat(" Dias com baixa utilização: ", n_low, "\n", sep = "")
235 cat(" Proporção: ", round(prop_low * 100, 2), "%\n", sep = "")

```

A.2 Script questão 3 (question3.R)

```

1 rm(list = ls()) #Cleaning environment
2 options(digits = 4)
3
4 # Set your folder path correctly (adjust if necessary before running!)
5 folder_path <- "/Users/fabiomachadomilan/Estatistica/codigos/Homework_1/"
6
7 load(paste0(folder_path, "data_group.RData"))
8 data_g10 <- data_group[1:10, ]
9
10 cat("CHECKING DATA LOADING\n")
11 cat(" > data_g10\n")
12 print(head(data_g10))
13 cat("\n > data_group\n")
14 print(tail(data_group))
15
16 cat("\n")
17 cat("Question 3: Low usage analysis\n")
18
19 # =====
20 # 1. Analyse system usage for each season of the year.
21 # For each season, calculate the mean, median, and standard deviation of total_user,
22 # and determine the proportion of days classified as low_usage. Construct a boxplot
23 # comparing the seasons and discuss the main differences observed.
24 # =====
25
26 cat("\n3.1 Per season usage\n")
27 cat("\n First 10th verification")
28 cat("\n Season: spring (only for the 10th)\n")
29

```

```

30 data_g10_spring <- subset(data_g10, season == 1)
31 spring_g10_total_users <- data_g10_spring$total_user
32
33 sum_10_spring <- sum(spring_g10_total_users)
34 n_10_spring <- length(spring_g10_total_users)
35 manual_mean_10spring <- sum_10_spring / n_10_spring
36
37 mean_10spring <- mean(spring_g10_total_users)
38 cat("  Manual mean = ", sum_10_spring, " / ", n_10_spring, " = ", mean_10spring, "\n", sep = "")
39
40 spring_g10_total_users_ordered <- sort(spring_g10_total_users)
41 cat("  Ordered values: ", spring_g10_total_users_ordered, "\n", sep = " ")
42 manual_median_10spring <- (spring_g10_total_users_ordered[5] + spring_g10_total_users_ordered[6]) / 2
43 cat("  Median = (", spring_g10_total_users_ordered[5], " + ", spring_g10_total_users_ordered[6], ") / 2 =
  ↪ ", manual_median_10spring, "\n", sep = "")
44
45 median_10spring <- median(spring_g10_total_users)
46
47
48 squared_deviations_10spring <- (spring_g10_total_users - manual_mean_10spring)^2
49 sum_sqr_dev_10spring <- sum(squared_deviations_10spring)
50 manual_variance_10spring <- sum_sqr_dev_10spring / (n_10_spring - 1)
51 manual_std_10spring <- sqrt(manual_variance_10spring)
52 cat("  Standard Deviation = ", manual_std_10spring, "\n", sep = "")
53
54 std_10spring <- sd(spring_g10_total_users)
55
56
57 manual_prop_low_10spring <- sum(data_g10_spring$low_usage) / nrow(data_g10_spring)
58 cat("  Proportion of low_usage days = ", manual_prop_low_10spring, "\n", sep = "")
59
60 prop_low_10spring <- mean(data_g10_spring$low_usage)
61
62 cat("\n  COMPARISONS")
63 cat("\n  Manual mean: ", manual_mean_10spring, " | R: ", mean_10spring, " | Difference: ",
  ↪ abs(manual_mean_10spring - mean_10spring), "\n", sep = "")
64 cat("  Manual median: ", manual_median_10spring, " | R: ", median_10spring, " | Difference: ",
  ↪ abs(manual_median_10spring - median_10spring), "\n", sep = "")
65 cat("  Manual std: ", manual_std_10spring, " | R: ", std_10spring, " | Difference: ",
  ↪ abs(manual_std_10spring - std_10spring), "\n", sep = "")
66 cat("  Manual low_usage days: ", manual_prop_low_10spring, " | R: ", prop_low_10spring, " | Difference:
  ↪ ", abs(manual_prop_low_10spring - prop_low_10spring), "\n", sep = "")
67
68 cat("\n All data_group")
69 cat("\n Season: SPRING\n")
70
71 data_spring <- subset(data_group, season == 1)
72 spring_total_users <- data_spring$total_user
73 mean_spring <- mean(spring_total_users)
74 median_spring <- median(spring_total_users)
75 std_spring <- sd(spring_total_users)
76 prop_low_spring <- mean(data_spring$low_usage)
77
78 cat("  n: ", length(spring_total_users), "\n", sep = "")
79 cat("  mean: ", mean_spring, "\n", sep = "")
80 cat("  median: ", median_spring, "\n", sep = "")
81 cat("  std: ", std_spring, "\n", sep = "")
82 cat("  low_usage days: ", prop_low_spring, "\n", sep = "")
83
84 cat("\n Season: SUMMER\n")

```



```

85
86 data_summer <- subset(data_group, season == 2)
87 summer_total_users <- data_summer$total_user
88 mean_summer <- mean(summer_total_users)
89 median_summer <- median(summer_total_users)
90 std_summer <- sd(summer_total_users)
91 prop_low_summer <- mean(data_summer$low_usage)
92
93 cat("      n: ", length(summer_total_users), "\n", sep = "")
94 cat("      mean: ", mean_summer, "\n", sep = "")
95 cat("      median: ", median_summer, "\n", sep = "")
96 cat("      std: ", std_summer, "\n", sep = "")
97 cat("      low_usage days: ", prop_low_summer, "\n", sep = "")
98
99 cat("\n Season: AUTUMN\n")
100
101 data_autumn <- subset(data_group, season == 3)
102 autumn_total_users <- data_autumn$total_user
103 mean_autumn <- mean(autumn_total_users)
104 median_autumn <- median(autumn_total_users)
105 std_autumn <- sd(autumn_total_users)
106 prop_low_autumn <- mean(data_autumn$low_usage)
107
108 cat("      n: ", length(autumn_total_users), "\n", sep = "")
109 cat("      mean: ", mean_autumn, "\n", sep = "")
110 cat("      median: ", median_autumn, "\n", sep = "")
111 cat("      std: ", std_autumn, "\n", sep = "")
112 cat("      low_usage days: ", prop_low_autumn, "\n", sep = "")
113
114 cat("\n Season: WINTER\n")
115
116 data_winter <- subset(data_group, season == 4)
117 winter_total_users <- data_winter$total_user
118 mean_winter <- mean(winter_total_users)
119 median_winter <- median(winter_total_users)
120 std_winter <- sd(winter_total_users)
121 prop_low_winter <- mean(data_winter$low_usage)
122
123 cat("      n: ", length(winter_total_users), "\n", sep = "")
124 cat("      mean: ", mean_winter, "\n", sep = "")
125 cat("      median: ", median_winter, "\n", sep = "")
126 cat("      std: ", std_winter, "\n", sep = "")
127 cat("      low_usage days: ", prop_low_winter, "\n", sep = "")
128
129 pdf(file = "/Users/fabiomachadomilan/Estatistica/Docs/assets/boxplot_season.pdf", width = 8, height = 6)
130
131 data_group$season_name <- factor(data_group$season,
132                                levels = c(1, 2, 3, 4),
133                                labels = c("Spring", "Summer", "Autumn", "Winter"))
134
135 boxplot(total_user ~ season_name,
136         data = data_group,
137         main = "Boxplot: Total Users per Season",
138         xlab = "Season",
139         ylab = "Total Users",
140         col = c("lightgreen", "orange", "yellow", "lightblue"))
141
142 dev.off()
143
144 # =====

```

```

145 # 2. Analyse system usage as a function of weather conditions.
146 # For each condition, calculate the mean and standard deviation
147 # of total_user, and determine the proportion of days classified as low_usage.
148 # Use appropriate statistical measures and plots to compare the weather conditions
149 # ("Clear", "Cloudy", "Light Rain", and "Heavy Rain").
150 # =====
151
152 cat("\n3.2 Per weather condition usage\n")
153 cat("\n First 10th verification")
154 cat("\n Weather Condition: clear \n")
155
156 data_g10_clear <- subset(data_g10, weathersit == 1)
157 clear_g10_total_users <- data_g10_clear$total_user
158
159 sum_10_clear <- sum(clear_g10_total_users)
160 n_10_clear <- length(clear_g10_total_users)
161 manual_mean_10clear <- sum_10_clear / n_10_clear
162
163 mean_10clear <- mean(clear_g10_total_users)
164 cat("    Manual mean = ", sum_10_clear, " / ", n_10_clear, " = ", mean_10clear, "\n", sep = "")
165
166 squared_deviations_10clear <- (clear_g10_total_users - manual_mean_10clear)^2
167 sum_sqr_dev_10clear <- sum(squared_deviations_10clear)
168 manual_variance_10clear <- sum_sqr_dev_10clear / (n_10_clear - 1)
169 manual_std_10clear <- sqrt(manual_variance_10clear)
170 cat("    Standard Deviation = ", manual_std_10clear, "\n", sep = "")
171
172 std_10clear <- sd(clear_g10_total_users)
173
174 # Added low usage for 10th clear
175 manual_prop_low_10clear <- sum(data_g10_clear$low_usage) / nrow(data_g10_clear)
176 prop_low_10clear <- mean(data_g10_clear$low_usage)
177
178 cat("\n    COMPARISONS")
179 cat("\n    Manual mean: ", manual_mean_10clear, " | R: ", mean_10clear, " | Difference: ",
180   ↪  abs(manual_mean_10clear - mean_10clear), "\n", sep = "")
181 cat("\n    Manual std: ", manual_std_10clear, " | R: ", std_10clear, " | Difference: ",
182   ↪  abs(manual_std_10clear - std_10clear), "\n", sep = "")
183 cat("\n    Manual low_usage: ", manual_prop_low_10clear, " | R: ", prop_low_10clear, " | Difference: ",
184   ↪  abs(manual_prop_low_10clear - prop_low_10clear), "\n", sep = "")
185
186 cat("\n Weather Condition: cloudy \n")
187
188 data_g10_cloudy <- subset(data_g10, weathersit == 2)
189 cloudy_g10_total_users <- data_g10_cloudy$total_user
190
191 sum_10_cloudy <- sum(cloudy_g10_total_users)
192 n_10_cloudy <- length(cloudy_g10_total_users)
193 manual_mean_10cloudy <- sum_10_cloudy / n_10_cloudy
194
195 mean_10cloudy <- mean(cloudy_g10_total_users)
196 cat("    Manual mean = ", sum_10_cloudy, " / ", n_10_cloudy, " = ", mean_10cloudy, "\n", sep = "")
197
198 squared_deviations_10cloudy <- (cloudy_g10_total_users - manual_mean_10cloudy)^2
199 sum_sqr_dev_10cloudy <- sum(squared_deviations_10cloudy)
200 manual_variance_10cloudy <- sum_sqr_dev_10cloudy / (n_10_cloudy - 1)
201 manual_std_10cloudy <- sqrt(manual_variance_10cloudy)
202 cat("    Standard Deviation = ", manual_std_10cloudy, "\n", sep = "")
203
204 std_10cloudy <- sd(cloudy_g10_total_users)

```

```

202
203 # Added low usage for 10th cloudy
204 manual_prop_low_10cloudy <- sum(data_g10_cloudy$low_usage) / nrow(data_g10_cloudy)
205 prop_low_10cloudy <- mean(data_g10_cloudy$low_usage)
206
207 cat("\n  COMPARATIONS")
208 cat("\n  Manual mean: ", manual_mean_10cloudy, " | R: ", mean_10cloudy, " | Difference: ",
  ↪ abs(manual_mean_10cloudy - mean_10cloudy), "\n", sep = "")
209 cat("\n  Manual std: ", manual_std_10cloudy, " | R: ", std_10cloudy, " | Difference: ",
  ↪ abs(manual_std_10cloudy - std_10cloudy), "\n", sep = "")
210 cat("\n  Manual low_usage: ", manual_prop_low_10cloudy, " | R: ", prop_low_10cloudy, " | Difference: ",
  ↪ abs(manual_prop_low_10cloudy - prop_low_10cloudy), "\n", sep = "")
211
212 cat("\n All data_group")
213 cat("\n Weather Condition: CLEAR\n")
214
215 data_clear <- subset(data_group, weathersit == 1)
216 clear_total_users <- data_clear$total_user
217
218 mean_clear <- mean(clear_total_users)
219 std_clear <- sd(clear_total_users)
220 prop_low_clear <- mean(data_clear$low_usage)
221 cat("      n: ", length(clear_total_users), "\n", sep = "")
222 cat("      mean: ", mean_clear, "\n", sep = "")
223 cat("      std: ", std_clear, "\n", sep = "")
224 cat("      low_usage days: ", prop_low_clear, "\n", sep = "")
225
226 cat("\n Weather Condition: CLOUDY\n")
227
228 data_cloudy <- subset(data_group, weathersit == 2)
229 cloudy_total_users <- data_cloudy$total_user
230
231 mean_cloudy <- mean(cloudy_total_users)
232 std_cloudy <- sd(cloudy_total_users)
233 prop_low_cloudy <- mean(data_cloudy$low_usage)
234 cat("      n: ", length(cloudy_total_users), "\n", sep = "")
235 cat("      mean: ", mean_cloudy, "\n", sep = "")
236 cat("      std: ", std_cloudy, "\n", sep = "")
237 cat("      low_usage days: ", prop_low_cloudy, "\n", sep = "")
238
239
240 cat("\n Weather Condition: LIGHT RAIN\n")
241
242 data_light_rain <- subset(data_group, weathersit == 3)
243 light_rain_total_users <- data_light_rain$total_user
244
245 mean_light_rain <- mean(light_rain_total_users)
246 std_light_rain <- sd(light_rain_total_users)
247 prop_low_light_rain <- mean(data_light_rain$low_usage)
248 cat("      n: ", length(light_rain_total_users), "\n", sep = "")
249 cat("      mean: ", mean_light_rain, "\n", sep = "")
250 cat("      std: ", std_light_rain, "\n", sep = "")
251 cat("      low_usage days: ", prop_low_light_rain, "\n", sep = "")
252
253
254 cat("\n Weather Condition: HEAVY RAIN\n")
255
256 data_heavy_rain <- subset(data_group, weathersit == 4)
257 # Checked with na.rm = TRUE in case category 4 has 0 days
258 if(nrow(data_heavy_rain) > 0) {

```

```

259 heavy_rain_total_users <- data_heavy_rain$total_user
260 mean_heavy_rain <- mean(heavy_rain_total_users)
261 std_heavy_rain <- sd(heavy_rain_total_users)
262 prop_low_heavy_rain <- mean(data_heavy_rain$low_usage)
263
264 cat("      n: ", length(heavy_rain_total_users), "\n", sep = "")
265 cat("      mean: ", mean_heavy_rain, "\n", sep = "")
266 cat("      std: ", std_heavy_rain, "\n", sep = "")
267 cat("      low_usage days: ", prop_low_heavy_rain, "\n", sep = "")
268 } else {
269   cat("      No Heavy Rain days in the dataset.\n")
270 }
271
272 pdf(file = "/Users/fabiomachadomilan/Estatistica/Docs/assets/boxplot_weather.pdf", width = 7, height = 4.5)
273
274 # Plotting the Weather condition comparison
275 data_group$weather_name <- factor(data_group$weathersit,
276                                   levels = c(1, 2, 3, 4),
277                                   labels = c("Clear", "Cloudy", "Light Rain", "Heavy Rain"))
278
279 boxplot(total_user ~ weather_name,
280         data = data_group,
281         main = "Boxplot: Total Users per Weather",
282         xlab = "Weather Condition",
283         ylab = "Total Users",
284         col = c("#a6cee3", "#1f78b4", "#b2df8a", "#33a02c"))
285 dev.off()
286
287 # =====
288 # 3. Investigate the relationship between temperature and total_user.
289 # Construct a scatter plot and calculate the correlation coefficient.
290 # Interpret the direction and strength of the association and discuss possible
291 # limitations of the correlation coefficient in describing the observed relationship.
292 # =====
293 cat("\n3.3 Temperature vs Total Users Correlation\n")
294 cat("\n First 10th verification\n")
295
296 temp_10 <- data_g10$temp
297 users_10 <- data_g10$total_user
298 n_10 <- length(temp_10)
299
300 mean_temp_10 <- mean(temp_10)
301 mean_users_10 <- mean(users_10)
302
303 # Deviations from the mean
304 dev_temp_10 <- temp_10 - mean_temp_10
305 dev_users_10 <- users_10 - mean_users_10
306
307 sum_prod_10 <- sum(dev_temp_10 * dev_users_10)
308 sum_sq_temp_10 <- sum(dev_temp_10^2)
309 sum_sq_users_10 <- sum(dev_users_10^2)
310
311 # Manual Pearson correlation formula
312 manual_r_10 <- sum_prod_10 / sqrt(sum_sq_temp_10 * sum_sq_users_10)
313 r_10 <- cor(temp_10, users_10)
314
315 cat("      Manual r = ", manual_r_10, "\n", sep="")
316
317 cat("\n      COMPARATIONS\n")
318 cat("      Manual r: ", manual_r_10, " | R: ", r_10, " | Difference: ", abs(manual_r_10 - r_10), "\n", sep="")

```

```

319
320
321 cat("\n All data_group\n")
322 # Cor in R for the full dataset
323 r_all <- cor(data_group$temp, data_group$total_user)
324 cat("    Correlation coefficient (r) = ", r_all, "\n", sep="")
325
326 pdf(file = "/Users/fabiomachadomilan/Estatistica/Docs/assets/scatter_temp.pdf", width = 12, height = 9)
327
328 # Scatter plot for total_user vs Temperature
329 plot(data_group$temp, data_group$total_user,
330       pch = 19, col = "darkblue",
331       main = "Scatter Plot: Temperature vs. Total Users",
332       xlab = "Temperature", ylab = "Total Users")
333 dev.off()
334
335
336 # =====
337 # 4. Based on the analyses performed in this question,
338 # select two characteristics that appear to be most strongly
339 # associated with system usage. Justify your choice based on
340 # the statistical and/or graphical results.
341 # =====
342
343 cat("\n3.4 Final Feature Selection\n")
344 cat("\n My choice: Temperature and Weather Conditions.\n")
345 cat(" Reason: Linear correlation confirmed by 'r' and scatter plot. Boxplots show maximum values declining
↪  when tending to rain, which makes a lot of sense since it is a bike system.\n")
346
347 pdf(file = "/Users/fabiomachadomilan/Estatistica/Docs/assets/boxplots_temp.pdf", width = 14, height = 4.5)
348 # Putting the final justification plots side-by-side
349 par(mfrow = c(1, 2))
350
351 # Plot A: Temperature by Season
352 boxplot(temp ~ season_name,
353         data = data_group,
354         main = "Temperature by Season",
355         xlab = "Season",
356         ylab = "Temperature",
357         col = c("lightgreen", "orange", "yellow", "lightblue"))
358
359 # Plot B: Temperature by Weather Condition
360 boxplot(temp ~ weather_name,
361         data = data_group,
362         main = "Temperature by Weather Condition",
363         xlab = "Weather Condition",
364         ylab = "Temperature",
365         col = c("#a6cee3", "#1f78b4", "#b2df8a", "#33a02c"))
366
367 par(mfrow = c(1, 1)) # Reset plot window
368 dev.off()

```

Referências

KERNS, G. J. *Introduction to Probability and Statistics Using R*. 1. ed. Ypsilanti, MI: G. Jay Kerns, 2010.

MAGALHAES, D. S. T.; MILAN, G. G. R.; SEABRA, G. O. *Repositório do Homework 1 de Estatística para Engenharia (TI0111)*. [S.l.]: GitHub, 2026. <<https://github.com/gustii17/Estatistica>>. Acesso em: 27 set. 2026.

MULAS, M. *TI0111-2026.2-L01_freq_distib (notes on slides)*. Fortaleza: Universidade Federal do Ceará, 2026. Apresentação de slides. Disciplina de Estatística para Engenharia (TI0111). Material didático não publicado.

MULAS, M. *TI0111-2026.2-L04_wrap_descriptive_stats (notes on slides)*. Fortaleza: Universidade Federal do Ceará, 2026. Apresentação de slides. Disciplina de Estatística para Engenharia (TI0111). Material didático não publicado.

MULAS, M. *TI0111_HW1_assignment*. Fortaleza: Universidade Federal do Ceará, 2026. Instruções do Homework 1. Disciplina de Estatística para Engenharia (TI0111). Material didático não publicado.

ROSS, S. M. *Introduction to Probability and Statistics for Engineers and Scientists*. 6. ed. San Diego, CA: Academic Press, 2020.